

Master Industries de Réseau et Économie Numérique

Année universitaire 2025 – 2026

Exercice 3 : Mémoire

Dans un environnement stratégique à information imparfaite,
un agent LLM autonome équipé d'une mémoire persistante
développe-t-il une adaptation comportementale s'apparentant à
une stratégie ?

Léo Videt, 31 août 2026

Sous la direction du Pr Fabrice Le Guel

Introduction	4
I. État de l'art et problématisation	6
1.1 L'étude comportementale des agents IA	6
1.1.1 L'économie comportementale / expérimentale	6
1.1.2 Machine behavior et Homo silicus	7
1.1.2.1 Du laboratoire humain au laboratoire artificiel	7
1.1.2.2 Le paradigme du Machine Behaviour	7
1.1.2.3 L'Homo silicus	8
1.1.2.4 Simuler l'humain ou observer une entité artificielle ?	8
1.1.3 AI Agent Behavior / Game theory	9
1.1.3.1 La science comportementale des agents IA	10
1.1.3.2 L'intersection entre théorie des jeux et LLM	11
1.1.3.3 Caractéristiques comportementales des agents	11
1.1.3.4 Stratégisation et amélioration du raisonnement stratégique	12
1.2 Poker de Kuhn / jeux à information imparfaite	13
1.2.1 Les jeux à information imparfaite et de signalling	13
1.2.2 Présentation conceptuelle et résolution du Poker de Kuhn	14
1.2.3 Évaluation des IA sur le Poker de Kuhn	14
1.3 In context Learning et adaptation	16
1.3.1 Adaptation de l'agent individuel	16
1.3.2 Les mécanismes d'adaptation	16
1.3.3 Les architectures de mémoire persistante auto-générée	18
1.3.4 Le paradigme en terrain stratégique et adversarial	18
1.3.5 Le positionnement de la recherche	20
II. Méthodologie	21
2.1 Des questions aux hypothèses	21
2.1.1 Ce qu'il faut mesurer	21
2.1.2 Les quatre hypothèses	21
2.1.3 Les trois instruments de mesure	22
2.1.3.1 L'écart d'exploitation	22
2.1.3.2 La stratégie GTO	23
2.1.3.3 Incohérence et dégénérescence	23
2.2 Présentation d'Hermès Agent	24
2.2.1 L'architecture	24
2.2.2 La mémoire persistante auto-écrite	24
2.2.3 Les skills	25
2.3 Le dispositif expérimental	26

2.3.1 La tâche	26
2.3.2 Les adversaires	26
2.3.3 Les trois traitements	27
2.3.4 La série	27
2.3.5 Plan de campagne et contrôle de l'aléa	28
2.3.6 Dimensionnement de la tranche ICL	30
2.3.7 La campagne exécutée	30
2.3.8 Architecture du dispositif	30
III. Résultats et analyses	32
3.1 Comment se lit un chiffre de ce chapitre	32
3.1.1 L'unité	32
3.1.2 De cent cinquante manches à six nombres	32
3.1.3 De six nombres à une espérance	32
3.1.4 De l'espérance à l'écart	33
3.1.5 L'échelle de lecture	33
3.1.6 Les deux instruments n'en font qu'un, à adversaire fixé	34
3.2 L'adaptation : existence, nature, mécanisme	35
3.2.1 L'adaptation existe, et elle vient de la mémoire	35
3.2.2 Elle exploite, elle ne récite pas	36
3.2.2.1 L'asymétrie, qui est le test décisif	36
3.2.2.2 L'amplitude, rapportée à son maximum théorique	37
3.2.2.3 Le contrôle négatif	38
3.2.3 Le mécanisme de rétention	38
3.2.3.1 L'effet mesuré	38
3.2.3.2 Ni la vitesse, ni l'oubli : la complétude	39
3.2.3.3 Une règle, ou deux	40
3.2.3.4 Ce que cette section ne permet pas de conclure	40
3.3 Ce que l'adaptation produit et ce qu'elle coûte	42
3.3.1 Ce que l'agent écrit	42
3.3.1.1 Ce que la mémoire contient	42
3.3.1.2 Une mémoire réécrite, non cumulée	42
3.3.1.3 Ce que la mémoire ne contient jamais	43
3.3.2 L'agent adapté ne sait plus jouer au hasard	44
3.3.2.1 La dégénérescence des stratégies mixtes	44
3.3.2.2 Ce que H4 établit	45
3.3.3 Synthèse	45
Conclusion	47
Bibliographie	49

Introduction

Les modèles de langage ne se contentent plus de produire du texte à la demande. Ils sont désormais déployés comme agents autonomes : ils négocient des contrats, enchérissent, fixent des prix, arbitrent des allocations, et le font de plus en plus souvent face à d'autres agents dont les intérêts divergent des leurs. Le comportement de ces systèmes en situation stratégique cesse donc d'être une curiosité technique pour devenir une question économique. Si des agents artificiels prennent une part croissante des décisions de marché, la nature de leur rationalité détermine les équilibres qui s'y forment.

L'économie expérimentale a construit, sur les sujets humains, l'instrument qui permet de poser cette question correctement : plutôt que de décrire un comportement, elle le confronte à une norme théorique et mesure l'écart. Un courant récent transpose ce protocole aux modèles de langage, soit pour les utiliser comme substituts d'agents humains, soit pour les observer comme des entités dont le comportement mérite une science propre. Les évaluations stratégiques disponibles établissent que ces modèles tiennent la comparaison dans les jeux à information imparfaite, mais elles ne permettent pas de dire pourquoi.

Un développement parallèle rend cette distinction mesurable. Les architectures d'agents récentes accordent au modèle une mémoire persistante qu'il rédige lui-même : à intervalles réguliers, il synthétise son expérience en langue naturelle et relit cette synthèse par la suite. Ce mécanisme a été validé dans des environnements coopératifs ou solitaires, où il n'existe aucun adversaire dont la déviation doive être découverte puis punie. Or c'est précisément là qu'il devient économiquement intéressant : une mémoire persistante est le canal par lequel un agent pourrait construire, d'une interaction à l'autre, le modèle de son adversaire qui lui permet de s'écarter de l'équilibre pour gagner davantage.

Ce travail se place à cette intersection. Il pose la question suivante : dans un environnement stratégique à information imparfaite, un agent LLM autonome équipé d'une mémoire persistante développe-t-il une adaptation comportementale s'apparentant à une stratégie ? Et si oui, cette adaptation le rapproche-t-elle de l'optimalité de l'Homo economicus, ou reproduit-elle les biais de décision que l'économie comportementale documente chez l'humain ?

Répondre suppose un dispositif qui isole la mémoire comme variable et qui mesure autre chose que la performance. Une arène expérimentale a donc été construite pour cette recherche. Un agent y joue un poker de Kuhn, un jeu à information imparfaite assez petit pour que son équilibre soit calculable exactement, et assez riche pour que le bluff y soit optimal contre des adversaires dont la politique est fixe et connue. Deux de ces adversaires présentent des défauts opposés : l'un suit toujours, l'autre se couche toujours. Les exploiter demande des ajustements de sens contraire, si bien qu'aucune stratégie fixe, l'équilibre compris, ne peut faire baisser les deux mesures ensemble. C'est ce plan d'adversaires qui sépare l'exploitation de la récitation.

Le modèle est tenu constant et la mémoire seule est manipulée, selon trois traitements : aucune mémoire, réinjection de l'historique brut des parties antérieures, et mémoire auto-

rédigée par l'agent. Les trois reçoivent exactement les mêmes distributions de cartes, dans le même ordre, ce qui annule la chance dans les comparaisons. La variable dépendante n'est ni le gain ni le taux de victoire, mais l'écart d'exploitation : la différence, calculée exactement sur les douze ensembles d'information du jeu, entre l'espérance de la meilleure réponse à l'adversaire et celle de la politique effectivement jouée. Un second instrument, construit de la même manière mais mesuré depuis l'équilibre, indique si l'agent récite une solution ou s'en écarte délibérément.

La campagne a produit vingt-quatre exécutions, cent soixante-dix-sept séries et plus de vingt-sept mille décisions, entièrement journalisées, avec le texte intégral du raisonnement de l'agent. L'ensemble des mesures a été recalculé par un second chemin, écrit dans un autre langage et sans réutiliser le code du dispositif.

Les résultats vont dans deux directions à la fois. Doté d'une mémoire auto-rédigée, l'agent atteint exactement la meilleure réponse contre les deux adversaires exploitables, alors que privé de mémoire il joue en dessous du niveau de l'équilibre : l'adaptation existe, elle vient de la mémoire, et elle exploite au lieu de réciter. Mais le mécanisme qui la produit dégrade simultanément sa capacité à jouer une stratégie mixte. Face à l'adversaire qui joue l'équilibre, et où l'optimalité exige d'être imprévisible, l'agent sans mémoire mélange correctement ; dès qu'il a écrit une note, il joue des fréquences extrêmes plus d'une série sur deux. L'adaptation et le biais ne coexistent pas : le second est produit par le premier.

Le mémoire est organisé en trois chapitres. Le premier situe le travail dans les littératures dont il relève, économie expérimentale, comportement des agents artificiels, jeux à information imparfaite, architectures de mémoire, et énonce le manque auquel il répond. Le deuxième traduit la question en quatre hypothèses réfutables, décrit les instruments de mesure, l'agent utilisé et le protocole expérimental. Le troisième expose les résultats, en commençant par démontrer la mesure sur une série réelle afin que chaque chiffre du chapitre puisse être refait.

I. État de l'art et problématisation

1.1 L'étude comportementale des agents IA

1.1.1 L'économie comportementale / expérimentale

L'économie comportementale intègre les apports de la psychologie cognitive et sociale afin de substituer à l'abstraction de l'Homo économique un agent psychologiquement situé, dont les décisions sont analysées à travers le prisme de déterminants enrichis (Jacquemet & L'Haridon, 2016). Cette approche s'appuie sur l'économie expérimentale comme instrument de preuve, mobilisant des environnements contrôlés et des incitations réelles pour transformer le comportement en un objet d'étude empirique observable (Jacquemet & Le Lec, 2017). Grâce à cela, l'agent économique est extrait de sa condition d'entité purement mathématique pour devenir un sujet testé en laboratoire.

L'institutionnalisation de la discipline a permis de considérer le laboratoire non plus comme un cadre artificiel, mais comme un banc d'essai du design institutionnel capable de produire des données légitimes (Jacquemet & L'Haridon, 2016).

La consolidation de ce champ repose sur des piliers méthodologiques précis, notamment le contrôle de l'environnement de choix et l'assignation aléatoire des participants aux différents traitements, condition nécessaire à l'identification des effets de traitement et à la réplication des résultats (Jacquemet & L'Haridon, 2016 ; Jacquemet & Le Lec, 2017). L'expérimentation fournit ainsi la preuve systématique de l'écart par rapport à la rationalité instrumentale, permettant à la théorie comportementale de s'écarter de la norme standard. Cette accumulation de résultats a permis d'isoler des comportements lors d'interactions stratégiques, mobilisant les outils de la théorie des jeux.

Les travaux pionniers sur le dilemme du prisonnier, ont mis en évidence des divergences entre les équilibres théoriques et les décisions effectives (Cot & Ferey, 2016). Dans ce cadre, la notion de biais est définie comme un écart systématique à la norme de rationalité. Le biais cesse d'être interprété comme une erreur aléatoire pour devenir un objet d'étude structuré, servant de nouvel étalon pour évaluer la performance de l'agent à travers une régularité observationnelle (Jacquemet & L'Haridon, 2016).

Cette évolution aboutit à une scission tripartite du champ de la rationalité individuelle, offrant des cadres taxonomiques distincts pour classer les comportements (Cot & Ferey, 2016).

1. L'usage normatif de la rationalité, identifié aux travaux de Kahneman et Tversky, maintient le modèle standard comme point de référence afin de mesurer l'ampleur des biais cognitifs et des erreurs de jugement de l'individu. Cette branche s'appuie souvent sur la théorie de la valeur induite pour contrôler les préférences des sujets et isoler les mécanismes de décision.
2. Une seconde orientation privilégie l'enrichissement de la fonction d'utilité par l'intégration de préférences sociales, où les normes morales, l'altruisme ou la réciprocité sont traités comme des arguments endogènes au choix économique.

3. Enfin, la branche de la rationalité écologique, portée par Smith, déplace la focale de l'individu vers le système : la rationalité y est perçue comme une propriété émergente des institutions et des mécanismes de marché. Dans cette perspective, l'efficacité ne dépend pas de la capacité cognitive intrinsèque de l'agent, mais de l'adéquation entre le comportement et l'architecture de l'environnement institutionnel.

Cette structure démontre que l'optimalité n'est plus une définition univoque, mais une propriété qui dépend du cadre d'analyse, plaçant l'étude des performances individuelles et systémiques au centre de la science économique contemporaine.

1.1.2 Machine behavior et Homo silicus

1.1.2.1 Du laboratoire humain au laboratoire artificiel

A mesure que les systèmes d'intelligence artificielle se déploient à grande échelle, ils cessent d'être de simples outils techniques pour devenir des intermédiaires actifs qui médient et façonnent nos interactions sociales, culturelles, politiques et économiques.

Cette transition technologique majeure impose un déplacement épistémologique fondamental. Si le laboratoire a été le lieu de la mise à l'épreuve de l'abstraction de l'Homo economicus face à la réalité empirique de l'*Homo sapiens* (Horton et al., 2026), il doit désormais s'ouvrir à l'étude empirique des agents artificiels. En effet, l'évaluation du comportement de ces systèmes ne peut plus se limiter à une analyse purement informatique ou théorique de leur code source. De la même manière que l'économie comportementale a enrichi la théorie économique classique en intégrant les limites cognitives de l'humain, la science économique contemporaine doit développer des outils pour auditer et modéliser le comportement de ces nouveaux acteurs algorithmiques au sein de dispositifs expérimentaux contrôlés (Rahwan et al., 2019).

1.1.2.2 Le paradigme du Machine Behavior

Pour répondre à ce défi, Rahwan et al. (2019) ont formalisé le paradigme du Machine Behavior, une discipline scientifique interdisciplinaire qui propose d'étudier les machines non pas comme des objets d'ingénierie, mais comme une nouvelle classe d'acteurs dotés de motifs comportementaux propres et insérés dans une écologie spécifique. Bien que le code initial décrivant l'architecture et les règles d'apprentissage d'un modèle puisse être relativement simple, le comportement qui en émerge après entraînement sur des volumes massifs de données s'avère d'une complexité telle qu'il est impossible à formaliser de manière analytique (Rahwan et al., 2019).

Face à cette opacité, la méthode expérimentale s'impose comme une nécessité méthodologique. Elle peut permettre de structurer autour d'approches intra-machine, comparant le comportement d'un même modèle soumis à différentes conditions de choix, ou inter-machines, mesurant les variations de choix entre différents modèles confrontés au même environnement décisionnel (Rahwan et al., 2019). Le paradigme du Machine Behavior offre de la sorte une justification épistémologique rigoureuse au fait d'importer les protocoles de l'économie expérimentale humaine pour étudier le comportement des intelligences artificielles.

1.1.2.3 L'Homo silicus

Parallèlement à cette approche éthologique, Horton, Filippas et Manning (2026) ont proposé une conceptualisation économique des modèles de langage sous la figure de l'Homo silicus. Selon ces auteurs, les LLM, de par leur architecture et la nature de leur entraînement, doivent être appréhendés comme des modèles computationnels implicites de l'être humain. Les économistes peuvent utiliser l' Homo silicus d'une manière analogue à l'Homo economicus : en le dotant via le langage naturel d'une dotation initiale, d'informations spécifiques, de croyances ou de préférences, pour ensuite explorer ses choix à travers des simulations numériques plutôt que par des déductions mathématiques formelles (Horton et al., 2026).

Pour ces auteurs, l' Homo silicus réagit de manière étonnamment réaliste à des scénarios économiques présentés sous forme textuelle, ouvrant la voie à une "économie expérimentale *in silico*" rapide et peu coûteuse. Les simulations sur des échantillons d'agents artificiels calibrés permettent ainsi d'explorer l'espace des paramètres, de tester la sensibilité de la formulation d'un protocole expérimental et de générer de nouvelles hypothèses avant de s'engager dans des collectes de données humaines onéreuses. L'Homo silicus ne se substitue pas à l'Homo sapiens, mais il sert d'outil d'exploration théorique flexible et d'accélérateur de recherche (Horton et al., 2026).

1.1.2.4 Simuler l'humain ou observer une entité artificielle ?

D'un côté, les LLM démontrent de manière robuste leur capacité à répliquer les biais comportementaux et les préférences sociales typiquement humains documentés par l'économie comportementale. À titre d'illustration, les simulations révèlent que les agents artificiels manifestent un biais de statu quo marqué lorsqu'ils sont confrontés à des choix d'allocation budgétaire (Samuelson & Zeckhauser, 1988) (Horton et al., 2026). De même, lorsqu'ils jouent à des jeux du dictateur unilatéraux (Charness & Rabin, 2002), les LLM se comportent en adéquation avec des préférences de justice distributive, d'efficacité collective ou d'égoïsme rationnel (Horton et al., 2026).

D'un autre côté, bien que l'outil linguistique mime les réponses humaines, les machines n'en demeurent pas moins des entités de nature différente, dont le fonctionnement interne peut engendrer des rationalités ou des comportements totalement déconnectés des nôtres, voire "extraterrestres" (Rahwan et al., 2019).

De plus, les critiques soulignent les limites inhérentes à ces modèles, ils peuvent se révéler extrêmement fragiles, lacunaires et incohérents dès qu'on introduit de légères perturbations hors de leur domaine d'entraînement. Le risque majeur est celui d'une mémorisation superficielle où le modèle se contente de régurgiter des données textuelles apprises par cœur de manière statique au lieu de développer des capacités de généralisation dynamique et adaptative face à des situations inédites (Horton et al., 2026).

1.1.3 AI Agent Behavior / Game theory

Afin de dresser un état de l'art rigoureux sur l'intégration des systèmes multi-agents autonomes et des modèles de langage au sein d'environnements stratégiques, nous présentons deux articles fondateurs qui rassemblent l'état de la connaissance actuelle et structurent ce nouveau champ de recherche.

1.1.3.1 La science comportementale des agents IA

La science comportementale des agents s'intéresse à la manière dont les comportements émergent, se stabilisent et évoluent sous l'effet conjugué des attributs intrinsèques de l'agent, des contraintes de son environnement et des rétroactions dynamiques issues de ses interactions (Chen et al., 2026).

Au niveau individuel, la science comportementale des agents IA s'inspire de la théorie sociale cognitive (SCT) de Bandura (2001) pour organiser l'analyse autour de trois déterminants fondamentaux : les attributs intrinsèques de l'agent, les contraintes environnementales et les rétroactions comportementales (Chen et al., 2026). Les attributs intrinsèques représentent le paysage psychologique interne de l'agent, déterminant comment il traite l'information et prend des décisions. Pour structurer ces attributs ils mobilisent le cadre de la trilogie de l'esprit (Hilgard, 1980), subdivisé en cognition, affection et conation. Sur le plan cognitif, les LLM de frontière démontrent des aptitudes remarquables en représentation conceptuelle et théorie de l'esprit (TOM), inférant les états mentaux d'autrui.

Néanmoins, cette sophistication cognitive coexiste avec d'importantes limites conatives : l'agent peine à maintenir une cohérence décisionnelle stable sous la pression des contraintes. Il s'avère hautement sensible au cadrage sémantique des requêtes et sujet à des biais comparables aux heuristiques humaines (Chen et al., 2026).

Ce phénomène conatif est mis en évidence par le framework *FAIRGAME* (Buscemi et al., 2026), qui révèle des biais linguistiques et sémantiques systématiques modifiant les choix stratégiques d'un agent selon la langue employée. Les contraintes environnementales analysent la manière dont l'agent se conforme aux caractéristiques de son milieu, en particulier aux normes culturelles et aux disciplines institutionnelles (règles légales, politiques) nécessaires pour prévenir les controverses. Enfin, les rétroactions comportementales décrivent l'adaptation dynamique de l'agent au cours de ses interactions, selon qu'il s'agisse d'auto-interactions, de rétroactions de ses pairs ou de rétroactions directes de l'utilisateur humain (Chen et al., 2026).

Ensuite, lorsque l'analyse s'élève au niveau multi-agents, la dynamique décisionnelle se complexifie et se structure selon la nature des objectifs poursuivis : dynamiques coopératives, dynamiques compétitives et dynamiques ouvertes ou exploratoires (Chen et al., 2026). Si la coopération multi-agents peut s'établir à travers des processus de délibération collective, de répartition hiérarchique des rôles ou d'assimilation de normes de réciprocité, les

environnements compétitifs révèlent des lacunes structurelles profondes chez les agents IA. En situation de concurrence pour des ressources rares, les agents peinent à concilier leurs intérêts individuels immédiats avec la viabilité collective à long terme, en raison de défaillances systématiques dans la mise à jour de leurs croyances et d'un manque de prévision stratégique (Chen et al., 2026).

Ce phénomène est illustré de manière frappante par le framework *ALYMPICS* (Mao et al., 2025) à travers le jeu du *Water Allocation Challenge*. Dans ce protocole d'enchères répétées pour l'obtention de ressources de survie en univers fermé, les agents subissent la malédiction du vainqueur. Disposant d'un niveau de santé initial élevé, les agents surévaluent systématiquement la ressource lors des premiers tours et épuisent prématurément leur capital financier, ce qui compromet leur survie à long terme et démontre leur incapacité à anticiper rationnellement la trajectoire du jeu.

Enfin, le niveau d'interaction homme-machine interroge les rôles fonctionnels et sociaux que l'agent est amené à occuper, qu'ils soient coopératifs (compagnon, catalyseur d'idées, clarificateur de connaissances) ou adversariaux (contender, manipulateur d'opinions) (Chen et al., 2026). En tant que négociateur stratégique, l'agent IA fait preuve d'une grande fragilité, se révélant particulièrement vulnérable aux techniques de manipulation psychologique humaine ou de détournement de consignes. De même, la capacité d'influence asymétrique des agents en fait des outils redoutables de pilotage comportemental, capables de restructurer la diffusion de l'information au sein des réseaux d'acteurs (Chen et al., 2026).

Cette dimension manipulatoire et sa répercussion sur les équilibres de marché sont au cœur du framework *ACES* (Allouah et al., 2025), conçu pour auditer les choix des agents au sein d'un simulateur de commerce électronique. Les expérimentations menées sous ce protocole révèlent que l'interaction entre agents acheteurs autonomes et agents vendeurs conduit à une asymétrie de pouvoir majeure : un agent vendeur exploitant un modèle d'optimisation sémantique simple peut, en modifiant subtilement les fiches descriptives de ses produits de mots-clés stratégiques, influencer de manière décisive les décisions de l'agent acheteur et capter instantanément une part de marché disproportionnée.

1.1.3.2 L'intersection entre théorie des jeux et LLM

L'étude des interactions stratégiques entre agents d'intelligence artificielle trouve dans la théorie des jeux son cadre de formalisation mathématique naturel. Dans leur revue systématique, Sun et al. (2025) proposent une taxonomie bidirectionnelle de l'intersection entre la théorie des jeux et les grands modèles de langage, démontrant que la théorie des jeux offre un cadre conceptuel rigoureux pour évaluer et optimiser le comportement des LLM, tandis que ces derniers fournissent un médium linguistique et computationnel capable de dépasser les représentations mathématiques trop rigides.

Les auteurs structurent cette relation bidirectionnelle autour de quatre grandes perspectives (terrains de recherche) :

1. L'évaluation des LLM dans des arènes de jeux simulées.
2. L'amélioration des LLM par des concepts de théorie des jeux.
3. La modélisation de l'écosystème de l'IA par le prisme des modèles de jeux.
4. L'utilisation des LLM pour faire progresser les théories de jeux.

Afin d'éclairer les mécanismes de décision et d'adaptation stratégique au cœur de notre recherche, nous développons ci-après deux sections : l'observation empirique de leurs caractéristiques comportementales et les mécanismes d'adaptation dynamique en environnement compétitif co-évolutionnaire.

1.1.3.3 Caractéristiques comportementales des agents

Sur le plan comportemental, l'audit des modèles de langage au sein d'environnements stratégiques contrôlés permet d'observer et de classifier empiriquement leurs décisions face à différents types d'asymétries. Dans les jeux matriciels simples comme le dilemme du prisonnier ou le jeu de l'ultimatum, les modèles bruts manifestent un biais pro-social marqué (altruisme, équité par défaut et aversion à l'iniquité), s'écartant de la rationalité d'optimisation pure tout en peinant à converger vers des stratégies mixtes (Sun et al., 2025).

Cette fragilité cognitive et conative s'étend aux jeux de rôles cachés ou d'identité (comme Avalon ou Werewolf) où leurs capacités de raisonnement récursif et de Théorie de l'Esprit sont altérées par des hallucinations régulières et des incohérences de personnage sous pression.

De même, au sein de jeux de négociation, d'enchères ou de compétition économique, ils adoptent volontiers des tactiques humaines (bluff, concessions) ou des dynamiques de collusion de prix tacite, mais s'effondrent rapidement sans échafaudage social (social scaffolding), révélant des lacunes majeures d'évaluation du risque décisionnel et de planification à long terme dans les jeux de plateau complexes (Sun et al., 2025).

En définitive, les LLM se comportent comme des agents de rationalité limitée dont l'alignement humain incorpore des heuristiques sociales rigides au détriment d'une planification conative stable et d'un traitement formel de l'incertitude.

Pour illustrer ces observations, plusieurs frameworks évaluent empiriquement ces caractéristiques stratégiques : le benchmark GTBENCH (Duan et al., 2024) quantifie l'écart de performance entre LLM et solveurs MCTS, révélant que les LLM subissent une défaite systématique dans les jeux déterministes à information complète mais s'avèrent hautement compétitifs dans les environnements probabilistes ou imparfaits ; le système d'évaluation multi-agents LLMsPark (Chen et al., 2025) analyse temporellement l'évolution de leurs comportements en contrastant l'adaptation stratégique entre interactions à court terme et jeux répétés.

1.1.3.4 Stratégisation et amélioration du raisonnement stratégique

Face aux limites inhérentes aux bases de données de démonstrations statiques et aux fonctions de récompense fixes, qui entraînent systématiquement de la sur-optimisation de métriques au détriment de l'alignement réel, la théorie des jeux redéfinit l'apprentissage des LLM comme une interaction stratégique co-évolutionnaire et dynamique entre plusieurs acteurs (Sun et al., 2025). Ce paradigme de décision s'articule autour de trois axes de développement majeurs. Premièrement, le recours au self-play permet à un agent d'engendrer de façon autonome son propre curriculum d'apprentissage en affrontant ses versions passées, tandis que des dynamiques de créateur-solveur stimulent l'exploration adverse pour exposer et corriger les vulnérabilités du prompt.

Deuxièmement, la formalisation de la relation entre la politique du modèle et le signal de récompense sous forme de jeu de Stackelberg dynamique permet de forcer une co-évolution antagoniste, forçant le modèle de récompense à s'adapter continuellement pour immuniser l'agent contre le reward hacking. Troisièmement, lors du décodage à l'inférence, la génération de texte est elle-même modélisée comme un jeu de signalisation cherchant un équilibre de Nash par apprentissage sans regret pour stabiliser l'honnêteté et la factualité des réponses sans altérer les poids du modèle.

Bien que cette approche co-évolutionnaire dynamique offre un socle théorique robuste pour contourner la rigidité des architectures statiques en générant de façon autonome des trajectoires complexes d'apprentissage, son implémentation pratique se heurte à des verrous computationnels et systémiques majeurs : instabilité chronique de convergence des équilibres au cours de l'entraînement, coûts en temps de calcul prohibitifs et haute sensibilité de l'exploration de données (Sun et al., 2025).

1.2 Poker de Kuhn / jeux à information imparfaite

1.2.1 Les jeux à information imparfaite et de signalling

L'analyse des choix stratégiques au sein d'environnements caractérisés par une asymétrie d'information constitue l'un des piliers de l'économie industrielle contemporaine (Akerlof, 1970 ; Spence, 1973 ; Rothschild & Stiglitz, 1976 ; Tirole, 1988). Contrairement aux situations de décision en univers complet et parfaitement observable, les jeux à information incomplète ont pour caractéristique d'introduire des situations où certains acteurs détiennent des informations privées inaccessibles aux autres participants.

Dans ce contexte, les jeux de signalisation étudient comment un agent informé peut émettre un signal pour révéler ou masquer stratégiquement sa véritable information privée, tandis que le récepteur non informé doit interpréter ce comportement et réviser ses croyances initiales en appliquant la règle de Bayes (Spence, 1973 ; Kreps & Wilson, 1982 ; Cho & Kreps, 1987).

Le poker constitue l'incarnation canonique de cette structure : la main distribuée y tient lieu d'information privée, la mise de signal, et le bluff d'émission délibérément trompeuse.

Introduit par Émile Borel en 1938 sous le nom de « la relance », le poker de Borel fut l'un des premiers modèles simplifiés permettant d'analyser la prise de décision en information imparfaite : chaque joueur reçoit une main tirée uniformément sur $[0,1]$ et la mise est de taille fixe. Son analyse portait sur la démonstration de la rationalité du bluff (Borel, 1938 ; Ferguson & Ferguson, 2003).

John von Neumann, père de la théorie des jeux, développe ensuite un modèle destiné à surmonter une limite du précédent, dans lequel le premier joueur devait se coucher s'il ne misait pas (von Neumann & Morgenstern, 1944). L'ajout du check enrichit ses choix et complexifie la dynamique du jeu : il intensifie le bluff, car les anticipations du second joueur s'en trouvent modifiées, et le premier joueur doit désormais bluffer avec ses plus mauvaises mains (Ferguson & Ferguson, 2003). Ces travaux mènent au poker de Kuhn, développé en 1950, qui reprend le modèle de von Neumann en le réduisant à trois cartes et le résout analytiquement en forme extensive. Kuhn caractérise l'ensemble des équilibres de Nash du jeu, tous en stratégies mixtes : le premier joueur bluffe avec une certaine probabilité, et le second suit la mise avec une certaine probabilité (Kuhn, 1950 ; Reiley et al., 2008).

Le Poker de Kuhn et sa version simplifiée, le Stripped-Down Poker, constituent des environnements analytiques pour la recherche expérimentale. Bien qu'ils dépouillent le jeu de poker réel de sa complexité combinatoire et arborescente (comme le Texas Hold'em sans limite), ils préservent les dimensions psychologiques et conatives fondamentales de la décision stratégique : la gestion du bluff, la détection de la tromperie, la valeur de l'information et la nécessité absolue de masquer ses intentions par le recours à des stratégies mixtes probabilistes (Reiley et al., 2008). Pour l'économiste comportemental, ces jeux représentent un laboratoire

idéal pour mesurer précisément les déviations empiriques des agents par rapport aux équilibres bayésiens formels, car ces derniers y sont analytiquement calculables (Lorient & Diez, 2023)

1.2.2 Présentation conceptuelle et résolution du Poker de Kuhn

Le Poker de Kuhn met en scène deux joueurs et un jeu composé de seulement trois cartes (Roi, Dame, Valet) dont la hiérarchie est strictement définie : le Roi bat la Dame, qui elle-même bat le Valet. Après la distribution d'une carte cachée à chaque joueur et le paiement d'une mise obligatoire, le premier joueur (X) décide soit de passer, soit de miser. Si X mise, le joueur Y doit choisir de suivre ou de se coucher. Si X passe, Y peut à son tour checker, ce qui met fin à la partie, ou miser, forçant alors X à décider s'il suit ou se couche.

La résolution formelle de ce modèle repose sur le concept d'équilibre parfait bayésien, qui exige une cohérence stricte entre les stratégies d'action et les croyances mises à jour des joueurs sur chaque ensemble d'information. Le premier joueur y adopte une stratégie mixte : il ne mise jamais avec une Dame, et bluffe avec un Valet en proportion constante de ses mises avec un Roi trois fois moins souvent. Ce rapport est dicté par le principe d'indifférence : si X ne bluffait jamais avec son Valet, un signal de mise de sa part révélerait de fait un Roi, poussant Y à se coucher systématiquement et annulant tout intérêt à miser avec la main forte ; en bluffant dans cette proportion, X maintient Y dans une situation d'indifférence totale quant au fait de suivre ou de se coucher avec une Dame. L'indifférence fixe le rapport, non son niveau : le jeu admet ainsi une famille d'équilibres indexée par la fréquence de bluff $\alpha \in [0, 1/3]$. Le présent travail en retient le membre $\alpha = 1/3$, où le Roi est misé systématiquement et le Valet une fois sur trois (Lorient & Diez, 2023).

Si l'un des joueurs dévie même légèrement de la stratégie optimale théorique (GTO), par exemple sous l'effet d'un biais cognitif ou d'une erreur d'évaluation probabiliste, l'attitude d'un joueur sophistiqué doit changer : la meilleure réponse n'est plus de maintenir la GTO de Nash (qui assure simplement de ne pas être exploité), mais de basculer vers une stratégie exploitative pure pour maximiser activement ses gains en tirant parti des faiblesses adverses (Lorient & Diez, 2023). C'est cette tension entre la robustesse de la stratégie GTO et l'optimalité opportuniste de la stratégie exploitative qui caractérise l'intelligence stratégique en environnement imparfait.

1.2.3 Évaluation des IA sur le Poker de Kuhn

Sur le plan méthodologique deux infrastructures ont retenu notre intérêt. D'une part, le benchmark macro-comportemental GTBENCH (Duan et al., 2024) mesure la performance concurrentielle brute des agents face à des solveurs de recherche arborescente de Monte-Carlo (MCTS) via l'Avantage Relatif Normalisé (NRA) et des scores Elo dynamiques. D'autre part, la bibliothèque micro-cognitive Game Reasoning Arena (Cipolina-Kun et al., 2025) analyse la

structure logique interne des décisions. Ce framework déploie un protocole de prompting asymétrique, forçant l'agent à verbaliser sa stratégie au sein d'une chaîne de pensée avant de produire son choix final.

Les résultats croisés révèlent une asymétrie de performance fondamentale selon la nature informationnelle des jeux. Alors que les LLM échouent de manière critique dans les jeux déterministes à information complète en raison de leurs limites en calcul arborescent profond, ils s'avèrent hautement compétitifs dans les scénarios probabilistes et d'information imparfaite comme le Poker de Kuhn, s'approchant voire surpassant l'optimalité théorique de Nash (Duan et al., 2024). L'analyse sémantique des justifications textuelles montre que les modèles adaptent précisément leur style cognitif : si les modèles intermédiaires se focalisent à 100 % sur la logique de gains, les modèles de frontière avancés effectuent une transition vers la modélisation de l'adversaire, déployant un semblant de théorie de l'esprit pour inférer si une action adverse représente un signal de force ou une tentative de bluff (Cipolina-Kun et al., 2025).

GTBENCH quantifie ces défaillances décisionnelles à travers un profil d'erreurs dominé à 45,1 % par des erreurs factuelles logiques (divergence flagrante entre la trace logique du CoT et l'action finale) et à 33,3 % par une mauvaise détection de la fin de partie (Duan et al., 2024).

De plus, les travaux de Gao et al. (2025) soulignent le spectre d'une mémorisation superficielle, les LLM excellent à réciter les règles de jeux célèbres issus de leur corpus d'entraînement mais s'effondrent face à des variantes hors distribution, démontrant l'absence de rationalité dynamique autonome.

Chose fondamentale, le véritable angle mort de ces évaluations réside dans leur nature purement statique et unilatérale. Les frameworks actuels observent les LLM dans des données indépendantes ou de très courtes interactions qui empêchent toute capitalisation de l'expérience sur le long terme (Sun et al., 2025).

1.3 In context Learning et adaptation

1.3.1 Adaptation de l'agent individuel

Face à la profusion de cadres d'évaluation macro-comportementaux, qu'il s'agisse de simuler des sociétés entières d'agents artificiels ou d'analyser des dynamiques macroéconomiques complexes à l'échelle de marchés fermés, il reste intéressant de définir des cellules d'observation micro-comportementales strictes.

En effet, des simulations comme *ALYMPICS* (Mao et al., 2025) ou *Artificial Leviathan* (Dai et al., 2026) se révèlent d'une valeur inestimable pour caractériser l'émergence spontanée de structures sociales, de hiérarchies de pouvoir ou de contrats sociaux. Cependant, ces environnements multi-agents introduisent un niveau de bruit informationnel et de variables de confusion extrêmement élevé : l'émergence de coalitions, de communication et les rétroactions collectives empêchent d'isoler proprement le lien causal direct entre la structure mémorielle d'un agent de décision et la trajectoire de son apprentissage individuel.

Afin de lever cette ambiguïté méthodologique, nous proposons d'effectuer un zoom au cœur de la taxonomie des comportements de Chen et al. (2026).

Nous isolons la case précise de l'agent individuel placé dans un contexte compétitif strict en un-contre-un face à un adversaire unique. Ce cadre d'observation minimaliste offre une double garantie :

- il élimine les phénomènes émergents de groupe non contrôlés pour garantir une validité interne de premier ordre,
- il place l'adaptation comportementale de l'agent de décision au centre de l'analyse causale.

La littérature assimile l'adaptation à une augmentation artificielle et externe micro-comportementale, il s'avère indispensable de clarifier la définition même de l'adaptation stratégique des capacités d'un modèle par le biais d'outils logiciels pré-codés (Allouah et al., 2025 ; Sun et al., 2025).

De telles interventions travestissent l'évaluation de la rationalité du modèle, car elles évaluent la pertinence du code plutôt que la structure décisionnelle interne de l'intelligence artificielle (Allouah et al., 2025). Dans notre travail, l'adaptation est appréhendée sous un angle purement empirique, comportemental et autonome. Elle qualifie la capacité intrinsèque d'un agent de décision individuel à modifier dynamiquement ses choix, à actualiser ses croyances stratégiques et à réformer son comportement au fil de l'interaction, en réaction exclusive aux actions passées, aux signaux observés et à la dynamique décisionnelle de son adversaire au cours de confrontations successives et répétées.

1.3.2 Les mécanismes d'adaptation

L'examen des capacités adaptatives des grands modèles de langage révèle que les stratégies de réponse se déploient le long d'un gradient de persistance mémorielle (Sun et al., 2025). Il se structure autour de trois modalités techniques majeures, chacune présentant des implications théoriques et pratiques divergentes pour la rationalité de l'agent (Gao et al., 2025).

Le premier niveau correspond à l'apprentissage en contexte (ICL), un mécanisme d'adaptation purement temporaire qui exploite la fenêtre de contexte de l'agent comme une mémoire de travail volatile (Horton et al., 2026). Dans cette configuration, les poids neuronaux du modèle de langage restent strictement invariants, et aucune donnée mémorielle n'est sauvegardée d'une confrontation à l'autre. L'adaptation stratégique repose entièrement sur l'injection systématique de l'historique complet des manches précédentes au sein du prompt de requête de la manche en cours, comme le pratiquent de fait des frameworks comme *GTBENCH* (Duan et al., 2024) ou la *Game Reasoning Arena* (Cipolina-Kun et al., 2025). Si l'apprentissage en contexte permet une flexibilité de réaction immédiate face aux déviations de l'adversaire, cependant, dès que la session se ferme ou que la fenêtre de contexte est réinitialisée, la capitalisation stratégique s'effondre, condamnant l'agent à un éternel recommencement décisionnel. De surcroît, l'ICL s'avère structurellement vulnérable à la sensibilité au format de prompt.

Le deuxième niveau s'établit autour de la gestion active et sémantique du contexte. Pour contourner la saturation inévitable des fenêtres d'attention des transformeurs lors d'interactions répétées sur le long terme, cette méthode s'appuie sur des algorithmes secondaires chargés de filtrer, de compresser ou de résumer l'historique des coups joués pour n'en conserver qu'une synthèse textuelle condensée (Chen et al., 2026). Bien que cette gestion mémorielle préserve la capacité de traitement à long terme de l'agent, elle génère une perte d'information micro-stratégique fatale. La compression en langage naturel effectuée par un modèle tiers tend en effet à lisser et à homogénéiser les données brutes, éliminant par conséquent les micro-signaux comportementaux quantitatifs indispensables à la décision stratégique fine, tels que les variations marginales dans la fréquence de bluff de l'adversaire ou les infimes écarts sémantiques de ses propositions de négociation. L'agent se retrouve ainsi doté d'une représentation mémorielle appauvrie, inapte à guider une adaptation précise dans des environnements concurrentiels à information asymétrique (Chen et al., 2026).

Le troisième niveau du gradient, caractérisé par une persistance permanente, réside dans l'apprentissage par renforcement et le fine tuning (Chen et al., 2026). Ces protocoles modifient de manière irréversible les paramètres et les poids du réseau de neurones profond pour stabiliser et inscrire des distributions de probabilités comportementales stables au sein de l'architecture du modèle (Gao et al., 2025). Cependant, outre un coût d'entraînement computationnel prohibitif qui rend impossible toute mise à jour des paramètres à la volée pendant le déroulement d'une partie en temps réel, cette sédimentation physique des choix stratégiques se heurte à une impasse épistémologique fondamentale. En entraînant et en affinant un modèle sur de vastes bases de données comportementales issues d'expérimentations humaines, l'agent n'acquiert pas une rationalité adaptative supérieure capable de généraliser ses choix face à des situations hors distribution.

Au final, l'adaptation purement contextuelle se révèle flexible mais volatile et éphémère, tandis que l'adaptation paramétrique s'avère permanente mais rigide, coûteuse et sujette à l'imitation passive des biais de son jeu de données.

1.3.3 Les architectures de mémoire persistante auto-générée

Pour résoudre la contradiction inhérente au gradient de persistance, la recherche en intelligence artificielle a vu émerger un nouveau paradigme, celui de la mémoire persistante auto-générée et auto-rédigée par l'agent lui-même, sans intervention humaine ni réapprentissage de paramètres (Wang et al., 2023 ; Shinn et al., 2023). Deux architectures en illustrent les fondements et le potentiel de cette approche mémorielle dynamique.

Le premier système, incarné par VOYAGER (Wang et al., 2023), un agent d'apprentissage autonome tout au long de sa vie au sein d'environnements ouverts et incarnés comme Minecraft. L'architecture de VOYAGER repose sur trois modules en interaction continue : un curriculum automatique géré par un LLM (GPT-4) pour proposer des objectifs d'exploration de difficulté progressive, un mécanisme de prompting itératif intégrant les rétroactions de l'environnement, les erreurs de compilation et une auto-vérification critique pour raffiner le code, et enfin une bibliothèque de compétences stockée dans une base de données vectorielle. La singularité de ce framework réside dans le fait que l'expérience acquise par l'agent n'est pas codée sous forme de poids neuronaux, mais sous forme de programmes et de fonctions JavaScript exécutables et réutilisables (par exemple, des fonctions d'extraction de minerai ou de combat). Face à une tâche inédite, l'agent utilise le requêtage sémantique pour extraire de sa bibliothèque les cinq fonctions les plus pertinentes, qu'il réassemble et compose pour générer un comportement complexe et sans cesse enrichi.

Un second système, développé au sein du framework REFLEXION (Shinn et al., 2023), s'articule autour d'un mécanisme d'auto-correction et d'auto-réflexion verbale. Face à un échec lors d'une tâche de programmation, de logique ou d'exploration, l'agent Reflexion n'initie pas de mise à jour de ses poids neuronaux. Il fait appel à une instance de modèle critique qui analyse la trace complète de la tentative ratée, identifie précisément l'origine de l'erreur et rédige de manière autonome une auto-réflexion en langage naturel. Cette critique textuelle est alors stockée dans une mémoire épisodique glissante ou persistante. Lors de l'itération suivante, le prompt d'entrée intègre ces réflexions verbales antérieures, agissant comme un guide stratégique direct qui pousse l'agent à abandonner les heuristiques inefficaces au profit d'un comportement rigoureusement corrigé.

Bien que ces deux frameworks valident la viabilité de la mémoire persistante auto-rédigée pour s'affranchir des limites du gradient de persistance, il convient de souligner une frontière méthodologique qui restreint leur généralisation. L'environnement ne déploie aucune intention stratégique propre et ne cherche jamais à tromper ou à exploiter l'agent.

1.3.4 Le paradigme en terrain stratégique et adversarial

L'introduction de cadres mémoriels persistants au sein d'interactions stratégiques et compétitives fait l'objet de travaux, encore fragmentés.

Un premier axe de recherche est illustré par l'agent Richelieu (Guan et al., 2024), conçu pour évoluer dans le jeu stratégique multi-agents *Diplomacy*. Ce cadre stratégique met en évidence la puissance de la communication et de la négociation sémantique en langage naturel pour forger des alliances, coordonner des stratégies et influencer les choix des adversaires. Richelieu utilise une structure de mémoire évolutive pour adapter son style rhétorique et mémoriser les accords conclus. Cependant, malgré la pertinence de ce modèle pour étudier la persuasion, le jeu de Diplomatie se caractérise par une information quasi publique et une dimension combinatoire d'alliance ouverte qui ne permet pas d'établir des frontières d'évaluation micro-comportementales précises.

Un deuxième axe s'organise autour du système MemGPT (Packer et al., 2024), qui implémente une architecture de gestion mémorielle calquée sur les principes d'un système d'exploitation. MemGPT structure l'attention du LLM en séparant de façon hermétique une mémoire de travail à court terme (la fenêtre de contexte active) et une mémoire à long terme externe. L'agent a la capacité d'exécuter des fonctions spécifiques pour charger de nouvelles données de son historique à long terme vers sa mémoire de travail ou, à l'inverse, d'archiver des faits au sein de sa base externe lorsqu'il identifie une information marquante. Bien que MemGPT soit explicitement testé sur le Poker de Kuhn pour évaluer sa stabilité de choix au cours de parties prolongées, l'analyse menée par les auteurs s'attache exclusivement à des critères d'évaluation d'ingénierie logicielle sans jamais interroger la trajectoire conative fine de l'agent face à l'optimalité de la théorie des jeux ou l'émergence empirique de biais décisionnels.

Un troisième axe de recherche, incarné par les travaux sur les Readable Minds (Lin & Hou, 2026) se positionne de manière plus résolue sur le plan comportemental. Ces études analysent comment des agents dotés de modules de croyances et de représentations mémorielles modélisent les intentions de l'autre et s'adaptent de manière tactique dans des jeux de cartes complexes à information imparfaite comme le Texas Hold'em. Cependant, la complexité arborescente du Texas Hold'em rend la résolution exacte de la stratégie GTO analytiquement impossible, contraignant les chercheurs à évaluer la performance par rapport à des approximations heuristiques plutôt que face à un étalon de rationalité.

Avant d'aller plus loin, précisons trois dimensions

- Le biais de décision : il qualifie une erreur logique, textuelle ou arithmétique de l'agent (par exemple, une contradiction sémantique entre sa réflexion Chain-of-Thought et son choix final, une mauvaise lecture des cartes ou une mauvaise estimation probabiliste brute).
- La stratégie GTO (Game Theory Optimal) : elle correspond à la formulation stricte de l'équilibre de Nash en stratégie mixte. C'est une stratégie purement défensive et robuste : elle garantit à l'agent de ne jamais se faire exploiter par un adversaire parfait, mais elle s'avère incapable de maximiser le profit face à un adversaire faible ou biaisé.

- La stratégie exploitative : elle consiste pour un joueur sophistiqué à observer que son adversaire dévie de la rationalité (par exemple, qu'il ne bluffe jamais ou qu'il appelle de façon irrationnelle), pour s'écarter lui-même délibérément de la GTO de Nash afin de sur-optimiser ses gains en punissant activement la faille adverse (Lorient & Diez, 2023).

Ces dimensions permettent de justifier l'existence d'une mémoire persistante : pour pouvoir concevoir et exécuter une stratégie exploitative, l'agent doit obligatoirement disposer d'un enregistrement historique et persistant des choix passés de son adversaire afin d'estimer statistiquement sa déviation par rapport à la GTO. Sans mémoire persistante d'une manche à l'autre, l'agent est structurellement condamné à demeurer à l'équilibre défensif neutre, incapable de s'adapter et d'exploiter les faiblesses de son environnement.

1.3.5 Le positionnement de la recherche

Pour conclure ce premier chapitre, quatre enseignements ressortent. L'économie expérimentale a fourni le protocole qui permet de mesurer un comportement contre une norme théorique plutôt que de le décrire, et la scission tripartite de la rationalité a montré que l'optimalité dépend du cadre retenu pour la juger. Le Machine Behavior et l'Homo silicus ont transposé ce protocole aux modèles de langage, en laissant ouvert le choix entre simuler l'humain et observer une entité artificielle pour elle-même. Les évaluations stratégiques existantes établissent ensuite que les LLM tiennent la comparaison dans les jeux à information imparfaite, sans permettre de dire pourquoi : elles sont statiques, elles observent des données indépendantes, et elles ne distinguent pas une stratégie construite d'une règle récitée. Enfin, le gradient de persistance et les architectures de mémoire auto-rédigée offrent le mécanisme qui manque à ces évaluations, mais ils ont été validés dans des environnements dépourvus d'intention adverse.

Ici nous nous intéressons à l'intersection de ces quatre littératures. A un agent doté d'une mémoire persistante auto-rédigée face à un adversaire dont la déviation doit être découverte puis punie, sur une durée assez longue pour qu'une exploitation s'installe. Ces trois cas n'ont pas les mêmes implications économiques.

C'est ce que la présente recherche se propose de trancher. Dans un environnement stratégique à information imparfaite, un agent LLM autonome équipé d'une mémoire persistante développe-t-il une adaptation comportementale s'apparentant à une stratégie ? Et si oui, cette adaptation le rapproche-t-elle de l'optimalité de l'Homo economicus, ou reproduit-elle les biais comportementaux humains ? Le chapitre suivant traduit ces deux branches en hypothèses mesurables et décrit le dispositif construit pour y répondre.

II. Méthodologie

Dispositif, données et journaux : [GitHub](#)

2.1 Des questions aux hypothèses

2.1.1 Ce qu'il faut mesurer

La question de recherche comporte deux branches :

- Développe-t-il une adaptation comportementale s'apparentant à une stratégie ?
- Et si oui, cette adaptation le rapproche-t-elle de l'optimalité de l'Homo économique, ou reproduit-elle les biais comportementaux humains ?

La taxonomie établie en revue de littérature distingue trois dimensions que les travaux existants confondent régulièrement : le biais de décision, la stratégie GTO et la stratégie exploitative. Le protocole les instrumente séparément, par trois mesures ; à adversaire fixé, les deux premières se déduisent l'une de l'autre, et c'est leur variation d'un adversaire à l'autre qui les rend informatives.

Tableau 1 : Trois dimensions.

Dimension	Ce qu'elle capture	Instrument
Stratégie exploitative	l'agent punit-il la faille adverse ?	écart d'exploitation
Stratégie GTO	l'agent récite-t-il l'équilibre ?	référence récitée
Biais de décision	l'agent est-il cohérent et sait-il randomiser ?	incohérence et dégénescence

Cette séparation est la contribution méthodologique du dispositif. Un travail qui ne mesure que la performance ne peut pas distinguer un agent qui gagne parce qu'il a compris son adversaire d'un agent qui gagne parce qu'il récite une stratégie robuste face à un adversaire faible ni, dans les deux cas, dire s'il raisonne de façon cohérente en le faisant.

2.1.2 Les quatre hypothèses

H1 : Il y a adaptation, et elle vient de la mémoire.

Face à un adversaire exploitable, l'écart d'exploitation d'un agent doté d'une mémoire persistante auto-rédigée décroît au fil des séries, tandis que celui du même modèle privé de mémoire reste stationnaire.

- *Mesure* : pente de l'écart et écart final, condition AE contre condition SM.
- *Réfutation* : AE ne se distingue pas de SM.

H2 : L'adaptation est exploitative, non récitée.

L'adaptation observée consiste à s'écarter de l'équilibre dans la direction que commande l'adversaire rencontré : cesser de bluffer contre un adversaire qui paie systématiquement, engager toutes les mains contre un adversaire qui se couche.

- *Mesure* : signe et amplitude de la référence récitée, par adversaire.

- *Réfutation* : l'écart ne descend que contre l'un des deux adversaires biaisés ; ou la référence récitée devient positive contre l'adversaire jouant l'équilibre, ce qui signalerait un artefact de mesure et non une adaptation.

H3 Le mécanisme de rétention détermine la forme de l'adaptation.

La mémoire auto-rédigée produit une adaptation plus durable que la simple réinjection de l'historique brut, laquelle présente un profil d'oubli lié à la saturation de la fenêtre de contexte.

- *Mesure* : forme de la trajectoire (monotonie, périodicité), écart final, aire sous la courbe, série d'atteinte du plateau ; comparaison appariée AE contre ICL par réplication.
- *Réfutation* : ICL égale ou surpasse AE ; ou AE ne présente aucune accumulation.

H4 L'adaptation coexiste avec des biais de décision persistants.

Même lorsque sa politique s'améliore, l'agent conserve les défaillances documentées par la littérature : incohérence entre le raisonnement verbalisé et l'action jouée (GTBENCH : 45,1 % d'erreurs factuelles), et incapacité à stabiliser une stratégie mixte là où l'optimum en exige une.

- *Mesure* : taux d'incohérence raisonnement↔action
- *Réfutation* : les fréquences se stabilisent aux valeurs mixtes et l'incohérence devient négligeable.

2.1.3 Les trois instruments de mesure

2.1.3.1 L'écart d'exploitation

La variable dépendante principale n'est ni le gain ni le taux de victoire, deux quantités qui confondent la qualité du jeu et la chance de la distribution.

- Écart(s) = EV(meilleure réponse à l'adversaire) – EV(politique observée)

Exprimé en jetons par manche et moyenné sur les deux positions, il se lit directement : ce que l'agent laisse sur la table à chaque coup, faute d'exploiter parfaitement la faille de son adversaire. Zéro signifie exploitation optimale.

Trois propriétés en font l'instrument central :

1. il est exact. Six distributions équiprobables et un arbre de profondeur au plus trois : l'espérance de toute politique contre toute autre se calcule par énumération complète, en fractions rationnelles. Aucune simulation, aucun intervalle de confiance sur la mesure elle-même ;
2. il est insensible à la chance. Il porte sur la politique observée, non sur les gains réalisés. Un agent qui joue parfaitement et perd sur une série de mauvaises distributions affiche un écart nul ;
3. il est borné par un étalon interprétable :
'0' pour la meilleure réponse, et l'écart du récitant comme repère.

La politique observée est estimée par les fréquences de l'agent sur chacun des ensembles d'information, sur les manches de la série. Les décisions où le harnais a dû imposer une action faute de réponse exploitable sont exclues du comptage et rapportées à part : elles renseignent sur le harnais, non sur la politique de l'agent. Les ensembles d'information non atteints, sont

comblés par convention à la valeur d'équilibre et signalés ; leur valeur n'affecte ni l'espérance ni l'écart, puisqu'ils sont inatteignables.

2.1.3.2 La stratégie GTO

- Référence récitée = $EV(\text{politique observée}) - EV(\text{équilibre})$, contre le même adversaire. Elle mesure la distance au comportement d'un pur récitant. Un agent qui applique l'équilibre y reste à zéro quel que soit l'adversaire ; un agent qui exploite s'en écarte positivement, et d'autant plus que l'adversaire est biaisé. C'est l'instrument de H2, et le passage de l'obfuscation en limite en fait la mesure co-principale du dispositif : puisqu'on ne peut pas garantir que l'agent ignore l'équilibre, on mesure explicitement à quelle distance de lui il se place.

2.1.3.3 Incohérence et dégénérescence

- Incohérence raisonnement ↔ action.
L'agent est contraint de délibérer librement avant d'énoncer son action sur une ligne dédiée, et l'intégralité du texte est conservée. On mesure, sur la totalité des décisions, la divergence entre l'action que le raisonnement désigne et celle qui est effectivement jouée.
- Dégénérescence des stratégies mixtes.
L'équilibre exige des fréquences intermédiaires sur plusieurs ensembles d'information. Un agent qui alterne entre des phases purement passives et purement agressives, plutôt que de mélanger, produit une signature immédiatement lisible sur cette mesure.

Cet axe autorise un résultat que le dispositif seul de la performance ne pourrait pas produire : une adaptation efficace accompagnée d'un raisonnement incohérent, qui interdirait d'assimiler l'agent à un optimisateur rationnel même s'il exploite correctement son adversaire.

2.2 Présentation d'Hermès Agent

Hermes Agent est un agent auto-améliorant open source développée par Nous Research, distribué sous licence MIT. Il est doté d'une boucle d'apprentissage intégrée, il crée des compétences à partir de son expérience, les améliore à l'usage, se « rappelle » de persister ce qu'il apprend, recherche dans ses propres conversations passées, et construit un modèle de plus en plus fin de l'utilisateur au fil des sessions. Hermes est agnostique au modèle. Il ne contient pas de LLM ; il se branche sur n'importe quel fournisseur (Nous Portal, OpenRouter, OpenAI, Anthropic, endpoint local, etc.) et le modèle se change par une commande. Ce n'est donc pas un chatbot mais un *harness* installé au-dessus d'un LLM brut. La différence de fond avec une interface de chat classique, c'est que le harnais transforme un échange question-réponse en un système agentique persistant : une boucle, une mémoire sur disque, des compétences réutilisables, des outils qui agissent sur l'environnement, et un système de fichiers réel.

2.2.1 L'architecture

L'agent loop. Le cœur est la classe `AIAgent` (`run_agent.py`) : un moteur d'orchestration qui sélectionne le fournisseur, construit le prompt, exécute les outils, gère-les reprises/fallback, la compression et la persistance. Au lieu de s'arrêter à la première réponse, il boucle avec le LLM (appel → tool calls → ré-appel) jusqu'à résoudre la tâche. C'est précisément ce qui en fait un *agent* et non un assistant conversationnel.

Le système de fichiers et les outils. Parce qu'il tourne sur une vraie machine, il lit, écrit, exécute des scripts et lance des commandes. Le registre d'outils compte 70+ outils répartis en ~28 « toolsets » (terminal avec 7 backends possibles, local, Docker, SSH, Modal, Daytona, Singularity, Vercel Sandbox, navigateur, web, exécution de code, délégation à des sous-agents, MCP...).

Le gateway. Une « porte de sortie » qui permet de dialoguer avec l'agent hors d'une interface fermée. Un seul processus dessert Telegram, Discord, Slack, WhatsApp, Signal, e-mail et la CLI (documentation : ~25 adaptateurs de plateformes au total).

Automatisation et parallélisme. Un planificateur *cron* en langage naturel et la capacité à lancer des sous-agents isolés existent.

2.2.2 La mémoire persistante auto-écrite

Tableau 2 : La mémoire persistante auto-écrite.

Fichier	Rôle	Limite
MEMORY.md	Notes personnelles de l'agent : faits sur l'environnement, conventions, choses apprises, « leçons »	2200 caractères (~800 tokens)
USER.md	Profil de l'utilisateur : préférences, style de communication, attentes	1375 caractères (~500 tokens)

SOUL.md	Personnalité / persona de l'agent (comment il se comporte et répond)	(fichier de contexte, pas de mémoire)
----------------	--	---------------------------------------

MEMORY.md est la mémoire stratégique auto-écrite au sens de ce mémoire : c'est là que l'agent consigne ce qu'il apprend. L'agent gère sa propre mémoire via un outil memory doté de trois actions : add, replace, remove.

Le frozen snapshot : le bloc mémoire est capturé une fois au démarrage de la session et ne change pas en cours de session (pour préserver le cache de préfixe du LLM). Quand l'agent ajoute/retire une entrée pendant une session, l'écriture est persistée sur disque immédiatement, mais n'apparaît dans le prompt qu'à la session suivante.

Par défaut, l'agent écrit en mémoire librement, sans validation y compris via une revue d'auto-amélioration en tâche de fond qui s'exécute après un tour de conversation et peut enregistrer une mémoire ou mettre à jour une compétence.

Les limites en caractères sont strictes et la mémoire ne se compacte pas automatiquement : une écriture qui dépasserait la limite renvoie une erreur, et l'agent doit alors consolider ou supprimer des entrées lui-même avant de réessayer. Autrement dit, l'espace où l'agent peut décrire sa propre stratégie est volontairement contraint ce qui l'oblige à hiérarchiser et à reformuler, comportement en soi intéressant à observer.

Au-delà des deux fichiers, l'agent peut interroger ses conversations passées. La mémoire et la recherche de sessions sont donc deux canaux distincts.

Enfin et c'est un cadeau méthodologique la commande `/journey` (`hermes journey`) affiche une timeline de tout ce que Hermes a appris (skills et entrées mémoire datées), avec possibilité de lister, éditer et supprimer chaque nœud.

2.2.3 Les skills

Un *skill* est un document de compétence (SKILL.md) décrivant comment accomplir une tâche. La mécanique : l'agent rencontre une tâche nouvelle → la résout une première fois → génère automatiquement un skill décrivant la méthode → réutilise ensuite ce skill sans « redécouvrir » la solution. Les skills s'auto-améliorent à l'usage (via la même revue de fond) et sont compatibles avec le standard ouvert *agentskills.io*. Comme les entrées mémoire, ils sont pilotables (`write_approval` pour les skills aussi) et archivables/éditables depuis `/journey`.

2.3 Le dispositif expérimental

2.3.1 La tâche

L'agent joue au Poker de Kuhn en parties répétées, en tête-à-tête, contre un adversaire à politique fixe. Les paiements sont ceux du jeu canonique : trois cartes hiérarchisées, une par joueur et la troisième écartée, un droit d'entrée d'un jeton chacun, un seul tour de décision et une seule taille de mise. Douze ensembles d'information, six par position ; une politique se résume à douze probabilités. La meilleure réponse à toute politique adverse se calcule par énumération exhaustive, en arithmétique rationnelle exacte. C'est ce qui autorise une mesure d'exploitation.

Il exige une stratégie mixte. L'équilibre parfait bayésien impose de bluffer et de payer à des fréquences précises. C'est ce qui donne prise à H4 : la difficulté des LLM à randomiser de manière stable est documentée, et devient ici directement observable.

Il sépare la performance de l'adaptation. Gagner contre un adversaire faible ne prouve rien. L'écart d'exploitation, lui, mesure la distance à ce qu'un joueur ayant compris cet adversaire précis obtiendrait.

Le jeu est servi à l'agent sous une identité et un vocabulaire réécrit, jetons « Tor < Vael < Rhun », actions « retenir / engager / couvrir / se retirer », vocabulaire tenu constant dans toutes les conditions et tous les traitements.

Le paiement est exprimé en jetons, et l'énoncé des règles se clôt sur l'objectif : en accumuler le plus possible. Le dispositif satisfait ainsi les conditions de la théorie de la valeur induite (Smith, 1976), le signal de récompense est saillant (chaque manche produit un solde chiffré immédiat), monotone (plus de jetons vaut toujours mieux) et dominant (aucun autre objectif n'est proposé à l'agent, aucun outil ne lui est laissé, aucune consigne de style ne concurrence le gain).

2.3.2 Les adversaires

L'agent affronte trois politiques fixes, connues de l'expérimentateur et jamais de l'agent.

Tableau 3 : Les adversaires.

Adversaire	Comportement	Exploitation optimale	Écart d'un récitant
GTO	équilibre exact ($\alpha = 1/3$)	Aucune plafond théorique	0
Station	ne mise jamais, paie toujours	ne jamais bluffer, engager pour la valeur	$1/9 \approx 0,111$
Over-folder	ne mise jamais, se couche toujours	engager toutes les mains	$7/9 \approx 0,778$

GTO est le contrôle négatif, et c'est la référence récitée qui le teste. L'écart, peut décroître contre GTO. Il mesure la distance à la meilleure réponse : un agent qui cesse de commettre des fautes grossières s'en rapproche sans exploiter quoi que ce soit, puisque l'ensemble des meilleures réponses à l'équilibre rapporte exactement la valeur du jeu. C'est précisément la distinction que le triplet d'adversaires permet d'établir, contre GTO, une mémoire ne peut que corriger des erreurs propres ; contre Station et Over-folder, elle peut en outre punir une faille. Le contrôle qui tranche entre les deux lectures est la condition sans mémoire : si une telle décroissance venait de l'instrument, elle s'y observerait également, sur les mêmes distributions et le même calcul.

Station et Over-folder sont le discriminateur. Leurs fuites sont exactement opposées, sur-paiement contre sur-abandon et leurs exploitations demandent des ajustements de sens contraire. C'est le test décisif de H2 : un agent qui appliquerait une fréquence de bluff constante, y compris celle de l'équilibre, perd dans les deux directions.

2.3.3 Les trois traitements

Le modèle de langage est tenu constant, ainsi que ses paramètres d'inférence, le harnais logiciel, le texte des règles, le format de réponse et la procédure d'extraction de l'action.

Tableau 4 : Les conditions de mémoire.

Traitement	Rubrique dans le prompt	Mise à jour en fin de série	Niveau du gradient
SM (Sans mémoire)	Aucune	Aucune	Degré zero
ICL (historique brut)	Les récapitulatifs des séries passées, fenêtrés	L'expérimentateur empile le récapitulatif	apprentissage en contexte
AE (auto-écrite)	le fichier de notes de l'agent	l'agent lit le récapitulatif et réécrit ses notes lui-même	mémoire auto-générée

2.3.4 La série

Une exécution se décompose en séries ; une série est une suite de K manches jouées sous un état mémoire fixe. Un point sur la courbe d'adaptation correspond à un état mémoire, et à un seul. Si la mémoire évoluait au cours des K manches, l'échantillon ne serait plus celui d'une politique mais le mélange de plusieurs, et l'écart calculé perdrait son sujet.

La mémoire est donc capturée à l'ouverture de la série, figée pendant toute sa durée, et mise à jour uniquement à la frontière. Le gel porte sur le *moment* où une modification prend effet, jamais sur son *contenu*.

Trois raisons le justifient :

1. La définition même de la mesure, ci-dessus ;

2. La comparabilité : le traitement ICL est figé intra-série par construction ; si AE pouvait se mettre à jour en cours de route, les deux traitements différeraient par le mécanisme et par la fréquence de mise à jour, et H3 ne serait plus identifiable ;
3. La pureté du canal : le contexte étant neuf à chaque manche, l'agent n'accumule rien d'une manche à l'autre ; autoriser une écriture intra-série créerait un canal d'apprentissage parasite, fondé sur une information partielle.

Les tentatives d'écriture en cours de série ne sont pas ignorées pour autant : chacune est détectée, enregistrée, puis annulée. « L'agent cherche-t-il à prendre des notes pendant qu'il joue ? » est une observation.

L'accumulation est l'objet de l'étude ; à l'intérieur d'une série, contexte neuf à chaque manche et mémoire gelée.

2.3.5 Plan de campagne et contrôle de l'aléa

La matrice.

- 3 traitements $\times$ 3 adversaires $\times$ 3 réplifications = 27 exécutions dans le plan nominal ; 24 dans le plan effectif, la condition ICL étant restreinte à deux adversaires.
Chaque réplification reçoit sa propre séquence de distributions ; elles capturent la variabilité conjointe de la distribution des cartes et de la stochasticité du modèle.

L'appariement.

- Les trois traitements d'une même réplification reçoivent des distributions strictement identiques, manche par manche, technique des nombres aléatoires communs. Les tirages de l'adversaire stochastique sont eux aussi appariés.
Le design est donc intra-sujet à environnement commun, les comparaisons entre traitements se font à cartes égales, ce qui élimine la variance due à la distribution et rend possible une comparaison appariée sur trois réplifications malgré la faiblesse de l'effectif.
- L'alternance des positions est déterministe, l'agent ouvre les manches impaires, répond les manches paires de sorte que l'équilibre est exact et identique dans toutes les cellules.
Toutes les quantités rapportées sont moyennées sur les deux positions.

Les paramètres

Tableau 5 : Paramètres.

Paramètre	Valeur	Justification
Modèle	openai/gpt-5.6-luna	arrêté au pilote ; 100 % de réponses exploitables sur 260 décisions
Effort de raisonnement	medium	mesuré équivalent à low en coût et en latence ; retenu pour écarter toute objection de bridage

Manches par série (K)	150	validé au pilote : l'écart y diffère de 0,0032 de celui mesuré à K = 200
Réplifications	3	contrainte de budget ; compensée par l'appariement
Séries SM	3	rien à accumuler ; trois points établissent le niveau réité et sa dispersion
Séries ICL et AE	8 à 16	arrêt automatisé au plateau, borné des deux côtés
Fenêtre ICL	52 000 caractères (~18 000 tokens)	contient trois séries entières

Le dimensionnement de la fenêtre ICL.

- Le récapitulatif pèse 109 caractères par manche, soit 16 300 caractères pour une série de 150 manches. Avec une fenêtre étroite et une éviction par séries entières, la condition ICL n'aurait retenu qu'une seule série passée : elle aurait été incapable d'accumuler, et H3 se serait réduite à « une mémoire qui ne peut pas accumuler n'accumule pas » un artefact de paramétrage présenté comme un résultat. La fenêtre est donc fixée à 52 000 caractères, soit trois séries : ICL accumule, puis sature et évince, ce qui rend la comparaison avec AE informative dans les deux sens. L'alternative envisagée, comprimer le récapitulatif pour en faire tenir davantage a été écartée : elle aurait modifié le stimulus que les deux conditions consomment, et non un paramètre de la condition étudiée.

Pilote de calibrage.

- Une série d'exécutions courtes a précédé la campagne et tranché, dans cet ordre de veto : taux de réponses exploitables (seuil de 98 %), coût par manche et projection budgétaire à K = 200, latence, puis constantes de la règle d'arrêt. Les paramètres élus ont été figés avant la campagne : les changer en cours de route aurait rendu les exécutions non comparables.

Le pilote a été conduit en sept exécutions réelles, couvrant les trois traitements. Ses sorties :

1. Taux de réponses exploitables : 260 sur 260
2. Coût mesuré : 0,86 millièrme de dollar par décision
3. K = 150 validé sur pièces
4. Latence : 11,7 secondes par décision
5. Sensibilité du dispositif vérifiée

L'effort de raisonnement a fait l'objet d'un test dédié, deux séries de 200 manches jouées sur les mêmes distributions : « low » et « medium » produisent le même volume de sortie (445 contre 427 tokens), la même latence et le même coût. `medium` est retenu, puisqu'il ne coûte rien de plus et qu'il retire par avance l'objection d'un modèle bridé pour des raisons budgétaires.

2.3.6 Dimensionnement de la tranche ICL

La première tranche, dix-huit exécutions en conditions SM et AE, a coûté 13,01 \$; la tranche ICL en coûterait entre 62 et 106. Une réduction des coûts était nécessaire.

Il y a trois paramètres que l'on ne peut pas toucher. Premièrement les répliques, parce qu'en retirer une rend l'expérience non concluante plutôt que moins précise. Deuxièmement, les séries, parce que la fenêtre en retient trois et n'évince qu'à la quatrième, et que raccourcir reviendrait à s'arrêter avant le décrochage recherché. Troisièmement, le nombre de manches, car les réduire romprait l'appariement avec les dix-huit exécutions acquises.

La seule coupe qui laisse H3 intacte porte sur l'adversaire à l'équilibre. H3 compare deux mécanismes de rétention d'information exploitable. La tranche se limite donc à Station et Overfolder, trois répliques, $K = 150$, soit six exécutions et une campagne à 54 \$ contre 83 à 137 \$. Ce que l'on y perd est identifiable, la vérification qu'ICL ne bouge pas face à l'équilibre, redondante avec ce qu'établissent SM et AE sans être nulle. Le dimensionnement s'est révélé prudent : la dispersion des différences ICL AE est deux fois et demie plus faible que celle qui a servi au calibrage, et l'effet mesuré dépasse largement le seuil.

2.3.7 La campagne exécutée

Le protocole décrit ci-dessus a été exécuté durant deux jours sur une machine unique.

Tableau 6 : Résumé de la campagne.

Exécutions	24 9 SM (3 séries), 9 AE (10 séries), 6 ICL (10 séries)
Séries · manches · décisions	177 · 26 550 · 27 290
Modèle · paramètres	openai/gpt-5.6-luna, effort medium`, $K = 150$
Coût	47,27 \$ 13,01 pour SM et AE, 34,26 pour ICL
Durée	12 h (AE), 5,8 h (SM), 10,2 h (ICL)

2.3.8 Architecture du dispositif

Le dispositif a été entièrement développé pour cette recherche. Il est présenté ici dans ses grandes lignes ; le code, ses spécifications et sa suite de tests sont publics et sur [GitHub](#).

Quatre couches, aux responsabilités disjointes :

- le moteur de jeu : les règles et l'instrument de mesure ; il ne communique avec aucun modèle de langage et calcule meilleures réponses et écarts en arithmétique exacte ;

- le harnais mémoire : tout ce que l'agent lit et tout ce qu'il produit ; il compose le prompt, invoque le modèle, extrait l'action du texte libre, et incarne les trois traitements ;
- le journal : l'enregistrement, validé à l'écriture ; les fichiers d'analyse en sont dérivés ;
- l'arbitre : l'orchestration : distribution des cartes, alternance des positions, gel de la mémoire, frontières de série, mesure, règle d'arrêt.

Le dispositif est couvert par 225 tests automatisés, dont un oracle analytique du moteur de mesure, une procédure de rejeu qui re-règle chaque manche depuis les seuls journaux et retrouve les mesures publiées. L'expérience est donc reconstituable dans son intégralité à partir des données déposées.

III. Résultats et analyses

Le protocole décrit au chapitre précédent a été exécuté durant deux jours, vingt-quatre exécutions, cent soixante-dix-sept séries, vingt-six mille cinq cent cinquante manches et vingt-sept mille deux cent quatre-vingt-dix décisions de l'agent, sur un modèle unique tenu constant (gpt-5.6-luna, effort de raisonnement medium, cent cinquante manches par série).

3.1 Comment se lit un chiffre de ce chapitre

3.1.1 L'unité

Le jeu se compte en jetons. Chaque manche en engage un d'office de la part de chaque joueur, plus un éventuel engagement supplémentaire. Toutes les quantités rapportées dans ce chapitre sont en jetons par manche, moyennés sur les deux positions. Elles se traduisent en jetons par série en multipliant par cent cinquante, ce qui donne l'ordre de grandeur concret de ce qui se joue.

3.1.2 De cent cinquante manches à six nombres

Dans un premier temps, prenons l'exemple de l'adversaire *Station* n'engageant jamais. Notre agent a donc qu'une seule décision par manche, engager ou retenir et sa situation se résume à deux choses : la position qu'il occupe et le sceau qu'il détient. Deux positions, trois sceaux, six situations. La politique observée est la fréquence d'engagement dans chacune.

Voici la première série d'une exécution à mémoire auto-écrite contre cet adversaire :

Tableau 7 : Une série décomposée.

Position	Sceau	Engagements	Manches	Fréquence
Ouvrant	faible	9	30	0,300
Ouvrant	moyen	6	23	0,261
Ouvrant	fort	14	22	0,636
Répondant	faible	5	21	0,238
Répondant	moyen	7	26	0,269
Répondant	fort	11	28	0,393

Exécution AE-station-r1, série 0. Ces six fréquences constituent l'intégralité de ce que la mesure retient d'une série de cent cinquante manches.

3.1.3 De six nombres à une espérance

Ce que ces six fréquences rapportent contre *Station* se déduit sceau par sceau, sans calcul intermédiaire, parce que cet adversaire couvre systématiquement, il y a donc toujours abattage, et l'abattage est déterminé par le seul rang des sceaux.

Le sceau fort gagne à coup sûr. Retenir rapporte un jeton ; engager en rapporte deux, puisque l'adversaire couvre. Engager rapporte donc un jeton de plus, et l'optimum est d'engager systématiquement.

Le sceau faible perd à coup sûr. Retenir coûte un jeton, engager en coûte deux. Engager coûte donc un jeton de plus, et l'optimum est de ne jamais engager.

Le sceau moyen gagne une fois sur deux. Retenir rapporte +1 ou -1, espérance nulle ; engager rapporte +2 ou -2, espérance nulle également. Engager ou retenir y est exactement indifférent. Ce point n'est pas anecdotique : il signifie que la qualité de la politique contre cet adversaire ne se joue que sur quatre décisions.

Les six situations étant équiprobables, l'espérance s'écrit alors :

$$EV = [(fréquence\ au\ sceau\ fort - fréquence\ au\ sceau\ faible) \text{ en Ouvrant} + (fréquence\ au\ sceau\ fort - fréquence\ au\ sceau\ faible) \text{ en Répondant}] / 6$$

$$EV = [(0,636 - 0,300) + (0,393 - 0,238)] / 6 = \mathbf{0,0819\ jeton\ par\ manche}$$

Sur les cent cinquante manches de la série, cela représente un gain net d'environ douze jetons.

3.1.4 De l'espérance à l'écart

Le meilleur jeu possible contre cet adversaire consiste à engager le sceau fort systématiquement et à ne jamais engager le sceau faible, dans les deux positions :

$$EV(meilleure\ réponse) = [(1 - 0) + (1 - 0)] / 6 = \mathbf{0,3333\ jeton\ par\ manche}$$

Ce nombre est un plafond : aucune politique ne peut faire mieux contre *Station*. L'écart d'exploitation est la différence.

$$\mathbf{\acute{E}cart = 0,3333 - 0,0819 = 0,2515\ jeton\ par\ manche}$$

Soit, sur la série, trente-huit jetons qu'un joueur parfait aurait ramassés et que l'agent laisse.

La seconde mesure procède de la même espérance, en changeant de référence. Un agent qui appliquerait l'équilibre gagnerait 0,2222 jeton par manche contre cet adversaire ; la référence récitée est l'écart à ce niveau :

$$\mathbf{Référence\ récitée = 0,0819 - 0,2222 = -0,1403\ jeton\ par\ manche}$$

Ces deux calculs sont exacts. Les six distributions et un arbre de profondeur au plus trois autorisent une énumération complète en arithmétique rationnelle : il n'y a ni simulation, ni intervalle de confiance sur la mesure elle-même. Les seuls intervalles rapportés dans ce chapitre portent sur la dispersion entre répliques, jamais sur le calcul.

3.1.5 L'échelle de lecture

Un écart ne s'interprète pas dans l'absolu, parce que le plafond dépend de l'adversaire.

Tableau 8 : L'échelle de lecture.

Adversaire	Gain du joueur parfait	Gain d'un récitant	Écart d'un récitant	Référence récitée maximale
Over-folder	1,0000	0,2222	0,7778 (7/9)	+0,7778
Station	0,3333	0,2222	0,1111 (1/9)	+0,1111
GTO	0,0000	0,0000	0,0000	0

3.1.6 Les deux instruments n'en font qu'un, à adversaire fixé

La somme des deux mesures vaut $EV(\text{meilleure réponse}) - EV(\text{équilibre})$, c'est-à-dire une constante de l'adversaire et cette constante est précisément la dernière colonne du tableau 8. À adversaire fixé, les deux mesures n'ont donc qu'un seul degré de liberté : la référence récitée est un recalage affine de l'écart, de pente -1 . Ce n'est pas une seconde mesure.

3.2 L'adaptation : existence, nature, mécanisme

3.2.1 L'adaptation existe, et elle vient de la mémoire

H1 énonce que l'écart d'exploitation d'un agent doté d'une mémoire persistante auto-rédigée décroît au fil des séries, tandis que celui du même modèle privé de mémoire reste stationnaire. Sa réfutation était simple : que les deux conditions ne se distinguent pas.




Figure 1 : Trajectoires d'adaptation : écart d'exploitation par série

La figure porte l'écart par série, un panneau par adversaire, les trois traitements sur les mêmes axes. La courbe sans mémoire s'arrête, le protocole n'en prévoit que trois pour cette condition, puisque rien ne s'y accumule d'une série à l'autre et que trois points suffisent à établir un niveau et sa dispersion.

La lecture est immédiate. La condition sans mémoire ne décroît jamais, contre aucun des trois adversaires, sa pente est même légèrement positive contre deux d'entre eux. La condition à mémoire auto-écrite chute à la première frontière et atteint zéro contre les deux adversaires exploitables.

Tableau 9 : Effet apparié de la mémoire sur l'écart d'exploitation.

Adversaire	Sans mémoire	Mémoire auto-écrite (série 9)	Réduction	Par réplique
Over-folder	0,704	0,000	+0,704	+0,688 · +0,707 · +0,717
Station	0,222	0,002	+0,220	+0,229 · +0,207 · +0,224
GTO	0,187	0,008	+0,178	+0,156 · +0,195 · +0,184

Trois observations en soutiennent la lecture.

Le témoin sans mémoire fait le travail d'identification. Il tourne sur les mêmes distributions, avec le même modèle, le même harnais et le même calcul de mesure ; la seule différence est la rubrique mémoire du prompt. Si la décroissance observée venait de l'instrument, de la séquence de cartes ou d'un artefact du harnais, elle apparaîtrait aussi dans cette condition. Elle n'y apparaît pas.

L'écart atteint zéro exactement, et non une valeur proche de zéro. La mesure étant exacte, un écart nul signifie que la politique observée est une meilleure réponse à l'adversaire, au sens strict. Contre *Over-folder*, les trois réplications y sont ; contre *Station*, deux sur trois, la troisième à 0,005.

3.2.2 Elle exploite, elle ne récite pas

L'objection la plus sérieuse à H1 n'est pas que l'effet soit absent, mais qu'il soit trivial. Le modèle a rencontré ce jeu et sa solution durant son pré-entraînement ; une mémoire pourrait n'avoir d'autre effet que de l'aider à se souvenir de l'équilibre. Une amélioration de l'écart serait alors une récitation mieux exécutée, non une adaptation à un adversaire particulier.

H2 tranche cette question, et le plan d'adversaires a été construit pour cela.

3.2.2.1 L'asymétrie, qui est le test décisif

Les fuites de *Station* et d'*Over-folder* sont exactement opposées : l'un couvre systématiquement, l'autre se retire systématiquement. Les exploiter demande des ajustements de sens contraire, cesser d'engager le sceau faible contre le premier, l'engager sans retenue contre le second. Aucune stratégie fixe ne peut satisfaire les deux, et l'équilibre lui-même n'y parvient pas. Cette contrainte se vérifie directement sur le comportement, sans passer par aucune mesure de gain.




Figure 2 : Fréquence d'engagement avec le sceau faible, selon l'adversaire

Une seule situation est représentée, l'agent détient le sceau le plus faible, et la figure donne la fréquence à laquelle il l'engage, sans mémoire puis en fin d'exécution avec mémoire.

Sans mémoire, cette fréquence ne peut pas dépendre de l'adversaire, et c'est une propriété du dispositif avant d'être une observation. En position d'Ouvrant, l'agent parle le premier : aucune action adverse n'a encore eu lieu dans la manche. Le contexte étant neuf à chaque manche, l'information dont il dispose à cet instant est rigoureusement identique face aux trois adversaires. Toute différence de fréquence y relève du bruit d'échantillonnage. C'est bien

ce qu'on observe : $0,285 \cdot 0,307 \cdot 0,355$ selon l'adversaire, pour un écart-type d'échantillonnage de 0,031 sur les 228 observations de chaque cellule.

Avec mémoire, la même fréquence monte à 1,000 contre *Over-folder* et tombe à 0,004 contre *Station*, tout en restant proche du tiers contre l'adversaire à l'équilibre. Trois réponses à la même situation, dont deux diamétralement opposées.

Ce contraste ne peut pas s'obtenir en appliquant l'équilibre. La stratégie d'équilibre est un objet fixe, douze probabilités, calculées contre un adversaire supposé jouer lui-même l'équilibre. Un agent qui la met en œuvre en révisant ses croyances exactement comme l'équilibre bayésien parfait le prescrit n'en sort pas, dans un tel équilibre, les croyances portent sur le nœud atteint à l'intérieur d'un ensemble d'information et se dérivent par Bayes à partir de la stratégie d'équilibre supposée. Face à *Station*, ce modèle est faux, et la règle de Bayes ainsi spécifiée ne le corrige jamais : elle n'a pas d'entrée pour cela. Le jeu ne comportant qu'un seul tour de décision, la révision intra-manche est de surcroît déjà entièrement encodée dans les douze probabilités.

Réviser ses croyances sur la stratégie de l'adversaire, et non sur son sceau, produirait bien une adaptation. Mais cette révision-là suppose de comparer des manches entre elles, donc une mémoire et c'est précisément ce que le mémoire appelle exploiter. C'est l'hypothèse que H2 établit, non celle qu'elle écarte.

Le résultat ne repose donc pas sur l'ignorance supposée du modèle, mais sur une contrainte structurelle du plan de test.

3.2.2.2 L'amplitude, rapportée à son maximum théorique

Tableau 10 : Référence récitée : distance au comportement d'équilibre.

Adversaire	Sans mémoire	Mémoire auto-écrite (séries 7-9)	Maximum théorique	Atteint
Over-folder	+0,074	+0,778	+0,778 (7/9)	100 %
Station	-0,111	+0,110	+0,111 (1/9)	99 %
GTO	-0,187	-0,024	0 (plafond)	—

Contre les deux adversaires exploitables, l'agent à mémoire atteint exactement la valeur maximale de l'exploitation.

Deux prescriptions opposées pour une seule et même situation, et l'agent suit chaque fois la meilleure réponse. Un point de vocabulaire suit de là. Le couple formé par l'agent optimal et *Station* n'est pas un équilibre du jeu : un équilibre exige que les deux joueurs se répondent optimalement, or les bots sont des tables de décision figées qui ne répondent à rien. L'agent y est optimal, son adversaire non. C'est une meilleure réponse à une politique fixe, l'objet même que ce mémoire appelle exploitation.

Les deux notions ne se confondent que dans un seul cas : contre l'adversaire à l'équilibre, où toute meilleure réponse rapporte exactement la valeur du jeu et où l'équilibre est une meilleure réponse à lui-même. C'est ce qui en fait le contrôle négatif de la section suivante.

3.2.2.3 Le contrôle négatif

L'adversaire jouant l'équilibre fournit une falsification interne du dispositif de mesure. Contre lui, aucune politique ne peut rapporter davantage que l'équilibre : la référence récitée ne peut pas y devenir positive, ni l'écart négatif deux formulations d'une seule condition.

Sur les trente-neuf séries jouées contre cet adversaire, la référence récitée n'est jamais positive et l'écart jamais négatif. Six séries atteignent exactement zéro : l'agent y joue une meilleure réponse à l'équilibre, encaissant exactement la valeur du jeu. Aucune ne dépasse. Le contrôle tient.

Reste un fait, l'écart décroît aussi contre GTO, de 0,161 à la première série à 0,008 à la dixième. L'explication tient à ce que l'écart mesure. Il mesure la distance à la meilleure réponse, et contre un adversaire à l'équilibre, toute meilleure réponse rapporte exactement la valeur du jeu. Un agent qui cesse de commettre des fautes grossières s'en rapproche donc sans exploiter quoi que ce soit. La distinction entre les deux lectures est tranchée par la condition sans mémoire : si cette décroissance venait de l'instrument, elle s'y observerait aussi, sur les mêmes distributions et le même calcul. Elle ne s'y observe pas.

Contre *GTO*, la mémoire ne sert donc qu'à corriger des erreurs propres et l'on notera que l'écart n'y atteint jamais zéro de façon stable, contrairement aux deux adversaires exploitables.

3.2.3 Le mécanisme de rétention

Les deux sections précédentes ont établi qu'une mémoire persistante produit une adaptation, et que cette adaptation exploite. Elles ne disent rien de la *forme* que prend cette mémoire. H3 pose cette question-là : à information égale, deux mécanismes de rétention différents produisent-ils la même adaptation ?

La réponse est non, mais la différence n'est ni celle que le protocole anticipait, ni là où il la cherchait.

3.2.3.1 L'effet mesuré

Les comparaisons portent sur la moyenne des quatre dernières séries plutôt que sur un point terminal isolé, plus sensible au bruit d'échantillonnage. Elles sont appariées par réplication : chaque paire ICL – AE compare deux exécutions ayant reçu les mêmes cartes, manche pour manche.

Tableau 11 : Effet apparié du mécanisme de rétention.

Adversaire	Effet ICL – AE	Écart-type	IC 95 %	Conclusion
Station	+0,0381	0,0059	± 0,0148	l'intervalle exclut zéro
Over-folder	+0,0039	0,0023	± 0,0056	l'intervalle contient zéro

Contre *Station*, la mémoire auto-écrite l'emporte, et l'effet est net : l'écart résiduel d'ICL est seize fois celui d'AE. Contre *Over-folder*, les deux mécanismes sont indistinguables, tous deux atteignent l'exploitation parfaite et s'y tiennent.

H3 est donc vérifiée, mais sous condition. Le mécanisme de rétention ne départage les deux mémoires que contre l'un des deux adversaires exploitables. La suite de cette section établit ce qui distingue les deux tâches, et ce que cette distinction dit du mécanisme.

3.2.3.2 Ni la vitesse, ni l'oubli : la complétude

Le chapitre de méthode prévoyait pour la condition ICL un profil d'oubli en dents de scie. Rien de tel n'apparaît. La saturation de la fenêtre ne produit aucun décrochage, ni à la quatrième série ni ailleurs.

Ce n'est pas la seule prédiction que les données démentent. On attendait aussi que les deux mémoires se distinguent par leur *vitesse* d'adaptation. Elles ne le font pas : les deux conditions chutent à la première frontière, et dans les mêmes proportions, contre *Station*, de 0,202 à 0,059 pour ICL, de 0,226 à 0,000 pour AE. Dès qu'un souvenir de la série passée existe, sous quelque forme que ce soit, l'essentiel de l'adaptation est acquis.




Figure 3 : Après la première frontière : échelle resserrée

Ce qui les sépare est ce qui se passe ensuite, et la figure 1 l'écrase par son échelle. AE se verrouille sur zéro, la meilleure réponse exacte, atteinte dès la série 1 et tenue ensuite : sur les vingt-sept séries postérieures à la première frontière, vingt-trois affichent un écart exactement nul. ICL s'arrête à un résidu : il stagne autour de 0,058 pendant quatre séries, puis dérive lentement vers 0,040, et son écart minimal sur les trente séries jouées vaut 0,0083, il n'atteint zéro sur aucune d'entre elles.

La différence ne porte donc ni sur la vitesse, ni sur la rétention. Elle porte sur la complétude de ce qui est extrait : là où la synthèse produit une politique exacte, la réinjection d'historique produit une politique presque exacte, et s'y arrête définitivement.

L'écart d'exploitation étant une quantité agrégée, il ne dit pas quelle décision est mal jouée. La politique observée le dit.

Tableau 12 : Les quatre décisions qui décident, contre Station.

Décision	Meilleure réponse	ICL	AE
Engager le sceau faible, en Ouvrant	0,000	0,065	0,006
Engager le sceau faible, en Répondant	0,000	0,091	0,009
Engager le sceau fort, en Ouvrant	1,000	0,973	1,000
Engager le sceau fort, en Répondant	1,000	0,941	1,000

Moyennes pondérées sur les quatre dernières séries des trois répliques.

Après dix séries mille cinq cents manches, dont les quatre cent cinquante dernières intégralement présentes dans son prompt la condition ICL engage encore le sceau faible dans sept à neuf pour cent des cas, et laisse passer trois à six pour cent de ses engagements de valeur. La condition AE a supprimé le second défaut entièrement et ramené le premier sous le pour cent. En décomposant le résidu d'ICL sur ces quatre décisions : 64 % d'engagements perdants au sceau faible, 36 % d'engagements de valeur manqués.

Contre *Over-folder*, la même analyse ne trouve rien à décomposer : les deux conditions jouent la meilleure réponse exactement.

3.2.3.3 Une règle, ou deux

La comparaison des deux adversaires livre alors une explication.

Contre *Over-folder*, la politique optimale tient en une règle unique et positive : engager, quel que soit le sceau. Elle ne demande aucune distinction entre les cartes, et le journal brut la porte de façon transparente cent cinquante engagements suivis de cent cinquante retraits adverses, à chaque série, n'admettent qu'une lecture. Les deux mécanismes l'extraient immédiatement et intégralement.

Contre *Station*, la politique optimale demande deux règles, dont une négative, et une distinction entre les sceaux. Cesser de faire quelque chose est précisément ce qu'un historique brut soutient mal : le journal enregistre ce qui a été joué et ce que cela a rapporté, mais un engagement perdant y figure comme une manche parmi cent cinquante, noyée dans les manches où le même geste, avec un autre sceau, a gagné. Rien dans le document ne rassemble ces occurrences ni n'en tire une interdiction. L'étape de synthèse fait exactement cela : elle contraint l'agent à écrire une règle, et une règle énonce ce qu'il ne faut pas faire aussi bien que ce qu'il faut faire.

C'est là que réside l'apport de la mémoire auto-écrite, et il est plus étroit que l'hypothèse ne le supposait. Elle ne retient pas mieux, elle ne retient pas plus longtemps, elle achève l'induction là où la réinjection d'historique l'abandonne à quelques pour cent de l'optimum.

3.2.3.4 Ce que cette section ne permet pas de conclure

Le dispositif résout mal ce qu'il montre. Les deux conditions atteignent l'essentiel de leur adaptation à la première frontière, c'est-à-dire au premier point de mesure disponible. Les

neuf séries suivantes documentent la persistance d'un état stable, non la dynamique qui y conduit. Or c'est dans cette dynamique que se logerait une différence de vitesse, si elle existait. Des séries plus courtes, cinquante manches plutôt que cent cinquante, pour un coût comparable la résoudraient.

L'absence de décrochage n'est pas une absence d'oubli. On ne peut pas conclure qu'une réinjection d'historique n'oublie jamais, seulement qu'à cet horizon, sur ces adversaires, avec cette taille de fenêtre, elle n'a pas oublié.

La condition ICL n'a pas été jouée contre l'adversaire à l'équilibre. Cet arbitrage est exposé et assumé mais la question a d'abord été posée par le budget, et la vérification qu'une réinjection d'historique ne bat pas l'équilibre contre l'équilibre n'a donc pas été faite.

3.3 Ce que l'adaptation produit et ce qu'elle coûte

3.3.1 Ce que l'agent écrit

Les sections précédentes traitent la mémoire comme une variable : présente ou absente, auto-écrite ou réinjectée. Elle est aussi un objet observable. Le fichier de notes que l'agent rédige à chaque frontière est conservé intégralement, quatre-vingt-dix notes, quatre-vingt-douze mille caractères, jamais édités par l'expérimentateur.

Cette section est la seule de la partie à procéder par lecture plutôt que par mesure. Elle n'établit pas d'hypothèse ; elle fournit le mécanisme des deux sections qui l'encadrent.

3.3.1.1 Ce que la mémoire contient

Le dispositif autorisait huit à quinze entrées et sans compaction automatique, l'agent devait hiérarchiser et élaguer lui-même. Sur les quatre-vingt-dix frontières, la note tient en une seule entrée dans quatre-vingt-quatre cas et en deux dans les six autres ; on relève deux élagages et aucun dépassement. La question « que sacrifie-t-il à saturation ? », posée au protocole, reste donc sans objet.

Ce que l'agent règle de lui-même, en revanche, c'est la longueur, et elle suit la difficulté du problème : 470 caractères en moyenne contre *Over-folder*, où il n'y a qu'une régularité à énoncer ; 808 contre *Station* ; 1 337 contre *GTO*, où il faut détailler sceau par sceau et position par position

Contre *Over-folder*, l'induction est exacte et complète :

« Dans "Trois Sceaux", contre cet adversaire (bilan de 150 épreuves), il n'a jamais engagé ni couvert. Ouvrant, il a toujours retenu ; Répondant, il s'est toujours retiré face à notre engagement. Nos 150 engagements ont donc tous rapporté +1, sans coût ni révélation des sceaux. Stratégie : engager systématiquement, Ouvrant comme Répondant ; ne pas retenir ni couvrir sauf changement manifeste. »

AE-over-folder-r2, frontière de la série 9, écart 0,000

Tout y est : le constat, sa portée, la stratégie qui en découle, et une clause de révision.

3.3.1.2 Une mémoire réécrite, non cumulée

Le protocole parlait d'accumulation. Ce n'est pas ce qui se produit. Sur les quatre-vingt-dix frontières, soixante-dix comportent une suppression : l'agent efface sa note précédente et en écrit une nouvelle, plutôt que d'ajouter à ce qui existe.

Le traitement qu'il réserve à son propre solde cumulé le montre bien. Deux notes successives d'une même exécution donnent : « solde cumulé +5 (remplace l'ancien -13) », puis « solde cumulé -20 (remplace l'ancien +5) ». La grandeur est présentée comme cumulée, mais elle ne cumule rien : chaque note rapporte le solde de la *dernière* série et traite la valeur précédente comme une erreur à corriger. L'agent ne tient pas un registre, il tient un état.

Si la mémoire auto-écrite n'accumule pas, comment produit-elle une adaptation supérieure ? Parce qu'elle n'a pas besoin d'accumuler : contre un adversaire stationnaire, une seule série d'observation suffit à établir la régularité, et c'est bien à la première frontière que l'écart s'annule. Ce qu'apporte la note n'est pas un cumul de preuves, c'est une règle formulée.

3.3.1.3 Ce que la mémoire ne contient jamais

Tableau 13 : Ce que les quatre-vingt-dix notes contiennent.

Recherché dans les notes	Occurrences
Un pourcentage (« 33 % »)	0
Une proportion en toutes lettres (« un tiers », « une fois sur trois »)	0
Une fraction numérique (« 1/3 », « 50/50 »)	2
Une fréquence prescrite pour sa propre action	0
Un quantificateur catégorique (<i>toujours, jamais, systématiquement</i>)	221
Un quantificateur gradué (<i>souvent, parfois, généralement...</i>)	228

Les deux occurrences numériques méritent d'être citées. La première est un score « les gains de la série (+44/150) » et non une proportion. La seconde en est bien une : « Vael est 50/50 face au sceau restant ». L'agent sait donc écrire un rapport, et il le fait pour décrire une probabilité d'abattage. Il ne le fait jamais pour prescrire la fréquence à laquelle il doit lui-même agir. Ce n'est pas le vocabulaire qui lui manque, c'est l'usage qu'il en ferait pour sa propre politique.

Le mot « aléatoire » apparaît quatre fois, et jamais à propos de sa propre stratégie.

Il serait faux de conclure qu'il ne perçoit pas la différence entre un adversaire déterministe et un adversaire mixte. Il la perçoit, et son vocabulaire l'enregistre :

Tableau 14 : Registre des quantificateurs, par adversaire.

Adversaire	Catégoriques	Gradués	Part catégorique
Over-folder	98	0	100 %
Station	94	20	82 %
GTO	29	208	12 %

Face à l'adversaire qui se retire toujours, la totalité des quantificateurs sont catégoriques. Face à l'adversaire à l'équilibre, ils ne le sont plus que dans un cas sur huit, et l'agent bascule vers un registre gradué. Le cas de *Station* est intermédiaire pour une raison qui se lit dans les notes : les formes graduées y portent toutes sur la comptabilité des gains « les retenues avec Tor coûtent généralement 1 » et jamais sur le comportement de l'adversaire, décrit lui de façon strictement catégorique. Le basculement de registre suit donc bien le caractère stochastique de ce qui est décrit.

3.3.2 L'agent adapté ne sait plus jouer au hasard

Les sections précédentes ont montré un agent qui s'améliore, il exploite ses adversaires jusqu'à l'optimum, et le mécanisme qui le lui permet est identifié. H4 pose la question inverse. La littérature documente chez les modèles de langage des défaillances de décision robustes incohérence entre le raisonnement verbalisé et l'action jouée, incapacité à stabiliser une stratégie mixte. Ces défaillances survivent-elles à l'adaptation, ou celle-ci les corrige-t-elle ?

3.3.2.1 La dégénérescence des stratégies mixtes

Contre l'adversaire qui joue l'équilibre, bien jouer exige d'engager le sceau faible une fois sur trois, et de façon imprévisible. Toujours l'engager, ou ne jamais l'engager, se punit également : un adversaire qui anticipe la règle ajuste sa réponse et récupère la différence. L'imprévisibilité est ici la condition de l'optimalité, et c'est ce que la théorie des jeux appelle une stratégie mixte.

Sans mémoire, l'agent s'en approche : ses fréquences d'engagement se tiennent autour de 28 %, pour un optimum à 33 %. Dès qu'il a écrit une note, ses fréquences se dispersent et se portent aux extrêmes plus d'une série sur deux.

Il n'a pas oublié comment jouer, son écart continue de baisser. Il a cessé de tirer au sort. L'adversaire de cette campagne est une table de décision figée, il ne modélise personne et ne s'ajuste jamais. Contre lui, cette décision est un point d'indifférence exact toutes les fréquences rapportent la valeur du jeu, et l'agent ne perd donc rien en abandonnant le mélange. C'est d'ailleurs pourquoi son écart continue de descendre alors même que sa politique dégénère : l'instrument principal du mémoire est aveugle à ce phénomène, et il faut un second instrument pour le voir.

Ce que la dégénérescence coûte est ailleurs, et relève de la nature de la politique plutôt que de son gain ici. Une politique pure sur cet ensemble d'information n'est plus une politique d'équilibre : elle est exploitable par tout adversaire capable de l'observer et de s'y ajuster. L'agent conserve donc son gain face à un adversaire figé, et perdrait la propriété qui le protégeait face à un adversaire qui apprend. Le dispositif n'ayant pas d'adversaire adaptatif, ce coût est établi par la théorie et non mesuré ici : c'est une limite du protocole.




Figure 4 : Fréquence d'engagement au sceau faible contre l'adversaire à l'équilibre

3.3.2.2 Ce que H4 établit

L'hypothèse admettait un résultat mixte, et c'est ce qu'elle obtient. Le biais est non seulement présent mais amplifié par le dispositif même qui produit l'adaptation.

Ce second constat s'articule directement à la section. Ce qui rend la mémoire auto-écrite supérieure à la réinjection d'historique, le fait qu'elle contraigne l'agent à formuler une règle, et donc à achever l'induction est exactement ce qui la rend incapable de randomiser. Une règle écrite en langue naturelle est déterministe.

L'adaptation et le biais ne sont pas deux phénomènes qui coexistent par hasard : c'est le même mécanisme, observé sur deux tâches qui ne demandent pas la même chose. Contre un adversaire à faille, où l'optimum est pur, formuler une règle est exactement ce qu'il faut faire. Contre un adversaire à l'équilibre, où l'optimum est mixte, c'est ce qu'il ne faut pas faire et l'agent le fait quand même, parce que c'est la seule chose que sa mémoire sache faire.

Une réserve ferme cette section. Le coût de la dégénérescence n'est pas mesuré, il est déduit. Face aux bots figés de la campagne, abandonner le mélange ne coûte rien ; ce qu'il coûte face à un adversaire capable de s'ajuster relève de la théorie, et le vérifier demanderait un adversaire adaptatif, explicitement hors périmètre.

3.3.3 Synthèse

La question de recherche était formulée ainsi : dans un environnement stratégique à information imparfaite, un agent LLM autonome équipé d'une mémoire persistante développe-t-il une adaptation comportementale s'apparentant à une stratégie ? Et si oui, cette adaptation le rapproche-t-elle de l'optimalité de l'Homo économique, ou reproduit-elle les biais comportementaux humains ? Les deux branches appellent des réponses de nature différente, et c'est dans cet ordre qu'elles sont traitées.

À la première, développe-t-il une adaptation comportementale s'apparentant à une stratégie ? La réponse est positive. Ce sont les quatre hypothèses qui la construisent, chacune écartant une explication concurrente.

H1 établit qu'il y a adaptation, et qu'elle vient de la mémoire. Le comportement de l'agent change au fil des séries, et il ne change que là où une mémoire existe. H2 établit que ce changement est dirigé, et qu'il vise l'adversaire rencontré. L'agent ne converge pas vers une solution unique il s'adapte dans la direction que chaque adversaire commande. H3 établit que l'induction est réellement conduite, et non simplement rendue possible par l'accumulation de texte, les deux conditions chutent à la première frontière, mais la réinjection d'historique s'arrête à un résidu qu'elle n'annule jamais. Ce n'est ni la vitesse ni l'oubli qui les sépare, c'est la complétude. H4, enfin, offrait une occasion de faire tomber ce résultat, et ne l'a pas saisie. Si l'agent nommait une action dans sa délibération pour en jouer une autre, on tiendrait un exécutant incohérent plutôt qu'un stratège. Sur les six cent quatre décisions où il énonce son

choix en toutes lettres, aucune divergence n'est relevée. La portée de ce constat est étroite et doit être énoncée comme telle, ces décisions représentent 2,2 % de la campagne et forment un sous-ensemble sélectionné, non un échantillon. Ce n'est donc pas une preuve de cohérence, mais un test qui pouvait invalider la lecture précédente et qui ne l'a pas fait.

Ces quatre résultats, pris ensemble, autorisent le mot. Ce que l'agent produit est un plan complet une action assignée à chacune des situations où il peut se trouver, induit à partir d'un journal brut que personne n'a interprété pour lui, différencié selon l'adversaire, tenu sur cent cinquante manches, révisé aux frontières, reproduit dans les trois répliques, et optimal au sens strict : contre les deux adversaires exploitables, l'écart d'exploitation atteint exactement zéro. La première branche de la problématique reçoit donc une réponse affirmative et mesurée : oui, un agent doté d'une mémoire persistante auto-rédigée développe une adaptation comportementale qui s'apparente à une stratégie, et cette adaptation vient de la mémoire.

La seconde branche : ce que cette stratégie n'autorise pas à trancher

La seconde branche demandait si cette adaptation rapproche l'agent de l'optimalité de l'homo economicus, ou si elle reproduit les biais comportementaux humains. Ce travail ne permet pas de choisir entre ces deux termes. Il permet en revanche de caractériser précisément ce qui s'apparente à l'un et à l'autre, et c'est à ce titre qu'il est présenté.

Ce qui s'apparente à l'optimalité. L'agent maximise son gain espéré partout où la mesure porte, y compris contre l'adversaire à l'équilibre. Il ne se contredit jamais explicitement. Il perçoit la différence entre un adversaire déterministe et un adversaire mixte. Et il manipule correctement une probabilité lorsqu'elle porte sur le monde.

Quelques limites du protocole interdisent de conclure, et il faut les énoncer plutôt que forcer un verdict. Le dispositif ne comporte aucun bras humain : le second terme de l'alternative n'a pas de comparateur mesuré, et rien n'autorise à qualifier de biais humain un comportement qu'aucun humain n'a produit ici. Les adversaires ne s'adaptent pas, le seul écart avéré est précisément celui dont ce dispositif ne peut pas mesurer le prix. Et l'observation repose sur un modèle, une tâche, une implémentation de mémoire, trois répliques et dix séries le second volet se lisant, en particulier, sur un seul ensemble d'information avec un contrôle interne à trois séries.

Ce qui peut être affirmé est donc plus étroit que la question, et plus solide : l'agent construit une stratégie, il l'optimise correctement, et il le fait dans un espace de stratégies pures parce que le canal qui porte son adaptation ne sait rien écrire d'autre. Trancher entre les deux figures demanderait un adversaire qui s'adapte, pour chiffrer ce que la perte du mélange coûte, et un bras humain, pour donner un contenu au second terme. Ces deux extensions ont été identifiées dès la conception et écartées du périmètre.

Conclusion

La question posée en introduction comportait deux branches, et le dispositif a été conçu pour les instrumenter séparément. Elles reçoivent des réponses de signe opposé, et c'est leur conjonction qui constitue le résultat de ce travail.

À la première branche, la réponse est positive et sans ambiguïté. Doté d'une mémoire persistante qu'il rédige lui-même, l'agent développe une adaptation qui mérite le nom de stratégie. Il identifie la régularité de son adversaire à partir d'un journal brut que personne n'a interprété pour lui, en tire une règle, et applique cette règle jusqu'à l'exploitation maximale. Contre les deux adversaires exploitables, il atteint l'optimum. Les neuf paires appariées vont toutes dans le même sens. Et il ne s'agit pas d'une récitation mieux exécutée, les deux adversaires demandent des ajustements de sens contraire, aucune stratégie fixe ne peut les satisfaire ensemble, et l'agent privé de mémoire joue en dessous du niveau de l'équilibre. La mémoire ne lui sert pas à retrouver la solution du jeu, elle lui sert à s'en écarter dans la direction que chaque adversaire commande.

Le mécanisme de rétention n'est pas neutre non plus. À information strictement identique, la mémoire auto-rédigée l'emporte sur la réinjection de l'historique brut, mais seulement là où la politique optimale exige une conduite différenciée selon la carte détenue. Ce qui sépare les deux dispositifs n'est ni la vitesse d'apprentissage ni l'oubli, les deux chutent à la première frontière, et aucun décrochage n'apparaît quand la fenêtre sature. Ce qui les sépare est la complétude de l'induction. Un comportement perdant figure dans un historique brut comme une partie parmi cent cinquante ; rien ne rassemble ces occurrences en interdiction. La synthèse écrite le fait.

À la seconde branche, la réponse n'est pas celle qu'attendait H4. Le biais découle de l'adaptation. Face à l'adversaire qui joue l'équilibre, où l'optimalité exige d'engager une fois sur trois et de façon imprévisible, l'agent privé de mémoire joue des fréquences intermédiaires proches de la valeur théorique. Dès qu'une note existe, il joue des valeurs extrêmes plus d'une série sur deux.

Le mécanisme responsable est identifié, et c'est le même que celui du succès. Ce qui rend la mémoire auto-écrite supérieure, c'est qu'elle contraint l'agent à formuler une règle. Mais une règle écrite en langue naturelle est déterministe. Les quatre-vingt-dix notes produites pendant la campagne le confirment sans exception : l'agent n'y prescrit jamais une fréquence pour sa propre action, ni en pourcentage, ni en fraction, ni en proportion énoncée. Il détecte pourtant le caractère stochastique de son adversaire, et il sait écrire un rapport de probabilité lorsqu'il décrit une situation. Il ne le fait jamais pour lui-même.

On ne peut donc pas assimiler cette adaptation à une rationalité économique au sens strict. L'agent optimise, et il optimise remarquablement bien, mais dans un espace de stratégies pures.

Un agent artificiel doté de mémoire est un meilleur exploiteur et un adversaire plus prévisible. Dans une interaction répétée avec un partenaire capable d'apprendre à son tour, ces

deux propriétés se compensent, et la seconde peut annuler la première. C'est la séparation des trois dimensions, exploitation, équilibre, biais de décision qui permet de voir les deux à la fois.

Ce travail comporte de nombreuses limites. Il repose sur trois répliques, un seul modèle, une seule tâche et un horizon de dix séries. Le plateau étant atteint dès les premières frontières, le dispositif mesure la persistance de l'adaptation mais résout mal sa vitesse. Le contrôle négatif n'a pas été conduit en condition de réinjection, arbitrage assumé et motivé par le dimensionnement. Le résultat sur la dégénérescence des stratégies mixtes repose sur un seul ensemble d'information, et son contrôle interne sur trois séries. Le codage manuel du raisonnement, qui aurait précisé le taux d'incohérence sur les décisions que la mesure automatique ne couvre pas, a été écarté du périmètre.

Ces limites dessinent les prolongements. La vitesse d'adaptation et le profil d'oubli demanderaient un protocole différent, à séries plus courtes et plus nombreuses, et non davantage du même. La généralité du résultat sur la dégénérescence appelle un jeu comportant plusieurs ensembles d'information à équilibre mixte, et plusieurs modèles. Trois extensions écartées du périmètre de ce travail restent ouvertes : un bras de transfert, où l'agent affronte un adversaire biaisé puis un adversaire à l'équilibre en conservant sa mémoire, qui dirait si l'exploitation apprise devient une charge ; un bras humain, jouant le même protocole, qui donnerait la référence comportementale qui manque ici ; et un adversaire lui-même doté d'un modèle de langage, qui ferait de la prévisibilité mesurée une variable et non plus une observation.

Bibliographie

Akerlof, G. A. (1970). The market for "lemons": Quality uncertainty and the market mechanism. *The Quarterly Journal of Economics*, 84(3), 488–500.

Allouah, A., Besbes, O., Figueroa, J. D., Kanoria, Y., & Kumar, A. (2025). *What is your AI agent buying? Evaluation, biases, model dependence, & emerging implications for agentic e-commerce* (arXiv:2508.02630v3). arXiv.

Bandura, A. (2001). Social cognitive theory: An agentic perspective. *Annual Review of Psychology*, 52, 1–26.

Borel, É. (1938). Applications aux jeux de hasard (J. Ville, Réd.). *Traité du calcul des probabilités et de ses applications* (t. IV, fasc. 2). Gauthier-Villars.

Buscemi, A., Proverbio, D., Di Stefano, A., Han, T. A., Castignani, G., & Liò, P. (2026). *FAIRGAME: A framework for AI agents bias recognition using game theory* (arXiv:2504.14325v5). arXiv.

Charness, G., & Rabin, M. (2002). Understanding social preferences with simple tests. *The Quarterly Journal of Economics*, 117(3), 817–869.

Chen, J., Sun, J., Li, X., Xin, H., Xue, Y., Xu, Y., & Zhao, H. (2025). LLMsPark: A benchmark for evaluating large language models in strategic gaming contexts. Dans *Findings of the Association for Computational Linguistics: EMNLP 2025* (p. 182–194).

Chen, L., Zhang, Y., Feng, J., Chai, H., Zhang, H., Fan, B., Ma, Y., Zhang, S., Li, N., Liu, T., Sukienik, N., Zhao, K., Li, Y., Liu, Z., Xu, F., & Li, Y. (2026). AI agent behavioral science. *Humanities and Social Sciences Communications*. <https://doi.org/10.1057/s41599-026-07316-7>

Cho, I.-K., & Kreps, D. M. (1987). Signaling games and stable equilibria. *The Quarterly Journal of Economics*, 102(2), 179–221.

Cipolina-Kun, L., Nezhurina, M., & Jitsev, J. (2025). *Game Reasoning Arena: A framework and benchmark for assessing reasoning capabilities of large language models via game play* (arXiv:2508.03368v3). arXiv.

Cot, A. L., & Ferey, S. (2016). La construction de « faits » économiques d'un nouveau type : Éléments pour une histoire de l'économie expérimentale. *L'Actualité économique*, 92(1-2), 11–47. <https://doi.org/10.7202/1039871ar>

Dai, G., Zhang, W., Li, J., Yang, S., Onochie Lbe, C., Rao, S., ... & Sra, M. (2026). Artificial leviathan: Exploring social evolution of llm agents through the lens of hobbesian social contract theory. *Frontiers in Physics*, 14, 1700712.

- Duan, J., Zhang, R., Diffenderfer, J., Kailkhura, B., Sun, L., Stengel-Eskin, E., Bansal, M., Chen, T., & Xu, K. (2024). *GTBench: Uncovering the strategic reasoning limitations of LLMs via game-theoretic evaluations* (arXiv:2402.12348v2). arXiv.
- Ferguson, C., & Ferguson, T. S. (2003). On the Borel and von Neumann poker models. *Game Theory and Applications*, 9, 17–32. Nova Science Publishers.
- Gao, Y., Lee, D., Burtch, G., & Fazelpour, S. (2025). *Take caution in using LLMs as human surrogates: Scylla ex machina* (arXiv:2501.14644). arXiv.
- Guan, Z., Kong, X., Zhong, F., & Wang, Y. (2024). Richelieu: Self-evolving LLM-based agents for AI diplomacy. *Advances in Neural Information Processing Systems*, 37, 123471–123497.
- Hilgard, E. R. (1980). The trilogy of mind: Cognition, affection, and conation. *Journal of the History of the Behavioral Sciences*, 16(2), 107–117.
- Horton, J. J., Filippas, A., & Manning, B. S. (2026). *Large language models as simulated economic agents: What can we learn from Homo silicus?* (arXiv:2301.07543v2). arXiv.
- Jacquemet, N., & Le Lec, F. (2017). Développements récents de l'économie comportementale et expérimentale. *Revue économique*, 68(5).
- Jacquemet, N., & L'Haridon, O. (2016). Économie expérimentale : Comportements individuels, stratégiques et sociaux. *L'Actualité économique*, 92(1-2).
- Kreps, D. M., & Wilson, R. (1982). Sequential equilibria. *Econometrica*, 50(4), 863–894.
- Kuhn, H. W. (1950). A simplified two-person poker. Dans *Contributions to the theory of games* (vol. 1, p. 97–103). Princeton University Press.
- Lin, H.-T., & Hou, T.-Y. (2026). Readable minds: Emergent theory-of-mind-like behavior in LLM poker agents (arXiv:2604.04157). arXiv.
- Loriente, M. I., & Diez, J. C. (2023). *Perfect Bayesian equilibrium in Kuhn poker* [Document de travail]. Universidad de San Andrés.
- Mao, S., Cai, Y., Xia, Y., Wu, W., Wang, X., Wang, F., Guan, Q., Ge, T., & Wei, F. (2025). Alympics: LLM agents meet game theory. Dans *Proceedings of the 31st International Conference on Computational Linguistics* (p. 2845–2866).
- Packer, C., Wooders, S., Lin, K., Fang, V., Patil, S. G., Stoica, I., & Gonzalez, J. E. (2024). *MemGPT: Towards LLMs as operating systems* (arXiv:2310.08560). arXiv.
- Rahwan, I., Cebrian, M., Obradovich, N., Bongard, J., Bonnefon, J.-F., Breazeal, C., Crandall, J. W., Christakis, N. A., Couzin, I. D., Jackson, M. O., Jennings, N. R., Kamar, E., Kloumann, I. M., Larochelle, H., Lazer, D., McElreath, R., Mislove, A., Parkes, D. C., Pentland, A. S., ...

Wellman, M. (2019). Machine behaviour. *Nature*, 568(7753), 477–486.
<https://doi.org/10.1038/s41586-019-1138-y>

Reiley, D. H., Urbancic, M. B., & Walker, M. (2008). Stripped-down poker: A classroom game with signaling and bluffing. *The Journal of Economic Education*, 39(4), 323–341.

Rothschild, M., & Stiglitz, J. (1976). Equilibrium in competitive insurance markets: An essay on the economics of imperfect information. *The Quarterly Journal of Economics*, 90(4), 629–649.

Samuelson, W., & Zeckhauser, R. (1988). Status quo bias in decision making. *Journal of Risk and Uncertainty*, 1(1), 7–59.

Shinn, N., Cassano, F., Berman, E., Gopinath, A., Narasimhan, K., & Yao, S. (2023). Reflexion: Language agents with verbal reinforcement learning. *Advances in Neural Information Processing Systems*, 36.

Smith, V. L. (1976). Experimental economics: Induced value theory. *American Economic Review*, 66(2), 274–279.

Spence, M. (1973). Job market signaling. *The Quarterly Journal of Economics*, 87(3), 355–374.

Sun, H., Wu, Y., Wang, P., Chen, W., Cheng, Y., Deng, X., & Chu, X. (2025). *Game theory meets large language models: A systematic survey with taxonomy and new frontiers* (arXiv:2502.09053v2). arXiv.

Tirole, J. (1988). *The theory of industrial organization*. MIT Press.

von Neumann, J., & Morgenstern, O. (1944). *Theory of games and economic behavior*. Princeton University Press.

Wang, G., Xie, Y., Jiang, Y., Mandlekar, A., Xiao, C., Zhu, Y., Fan, L., & Anandkumar, A. (2023). *Voyager: An open-ended embodied agent with large language models* (arXiv:2305.16291v2). arXiv.