

Soutenance de mémoire

Sujet : Dans un environnement stratégique à information imparfaite, un agent LLM autonome équipé d'une mémoire persistante développe-t-il une adaptation comportementale s'apparentant à une stratégie ?

1. Motivations

Les modèles de langage ne produisent pas seulement du texte.

- Agents autonomes : ils négocient des contrats, enchérissent, fixent des prix, arbitrent des allocations.
- Face à d'autres agents dont les intérêts divergent des leurs.
- L'enjeu est économique : la nature de leur rationalité détermine les équilibres qui se forment sur les marchés.

Cas observés à mon échelle

- L'IA outille, chez FDJ United, un dispositif de veille augmenté où l'analyse automatique filtre plus de 100 articles par semaine.
- Elle entre dans les process dans une maison de luxe, 5 cas d'usage prototypés pour le retail.
- Dans un groupe industriel, la question posée au COMEX n'est plus l'outil mais la feuille de route.
- Puis elle agit seule. J'ai construit un assistant qui cartographie une chaîne de valeur : cinq minutes, contre plusieurs heures.

QUESTION DE RECHERCHE

Dans un environnement stratégique à information imparfaite, un agent LLM autonome équipé d'une mémoire persistante développe-t-il une adaptation comportementale s'apparentant à une stratégie ?

2. Revue de littérature

L'économie comportementale et expérimentale

- Substituer à l'Homo economicus un agent psychologiquement situé.
- Le laboratoire comme instrument de preuve
- Le biais devient un écart systématique à une norme, un objet structuré

Du laboratoire humain au laboratoire artificiel

- Rahwan et al. (2019) : étudier les machines comme une classe d'acteurs, pas comme du code,
- Horton et al. (2026) : le LLM comme modèle computationnel implicite de l'humain, doté par le langage d'une dotation et de croyances.
- Simuler l'humain, ou observer une entité artificielle pour elle-même.

Le terrain, le poker de Kuhn

- Borel (1938) → von Neumann (1944) → Kuhn (1950) : le bluff est rationnel, l'équilibre est en stratégies mixtes.

2. Revue de littérature

Le gradient de persistance

- ICL : la fenêtre de contexte comme mémoire de travail volatile. Flexible, mais tout s'effondre à la fermeture de la session.
- Gestion sémantique : résumer pour ne pas saturer, au prix des micro-signaux quantitatifs.
- RL et fine-tuning permanent, mais rigide, coûteux, et imitant passivement les biais du jeu de données.

La mémoire auto-rédigée

- Voyager (Wang et al., 2023) : l'expérience stockée en programmes réutilisables, jamais en poids.
- Reflexion (Shinn et al., 2023) : l'agent analyse son échec, rédige une auto-réflexion en langue naturelle, la relit au tour suivant.
- Ces architectures sont validées dans des environnements qui ne cherchent jamais à tromper l'agent.

Le manque, et le positionnement

- Information quasi publique, critères d'ingénierie, ou équilibre non calculable.
- Trois dimensions confondues : biais de décision, stratégie GTO, stratégie exploitative.
- Sans mémoire persistante, un agent est condamné à l'équilibre défensif

3. Méthodologie

La tâche

- **Poker de Kuhn** : 3 cartes, 1 jeton d'ante, une mise, 12 ensembles d'information.
- **Vocabulaire réécrit partout**

Les trois adversaires

- **GTO** : équilibre exact ($\alpha = 1/3$). Rien à exploiter : le contrôle négatif.
- **Station** : ne mise jamais, paie toujours.
- **Over-folder** : ne mise jamais, se couche toujours.

Les trois traitements

- **SM** : aucune mémoire.
- **ICL** : les récapitulatifs passés empilés, fenêtre de 52 000 caractères (trois séries).
- **AE** : le fichier de notes que l'agent lit et réécrit lui-même.

La série

- Une série = **K = 150 manches jouées sous un état mémoire fixe**. Un point de courbe correspond à un état mémoire.
- La mémoire est capturée à l'ouverture, figée pendant la série, mise à jour à la seule frontière ; contexte neuf à chaque manche. Les écritures intra-série sont détectées, enregistrées, puis annulées.
- Appariement : les trois traitements d'une même réplification reçoivent les mêmes distributions, manche par manche, nombres aléatoires communs.

3. Méthodologie

L'écart d'exploitation

Écart = EV(meilleure réponse) – EV(politique observée)

- **Exact** : six distributions, arbre de profondeur trois
- **Insensible à la chance**, les résultats portent sur la politique, pas sur les gains réalisés.
- **En jetons par manche**. Zéro signifie exploitation optimale.

La référence récitée

Référence = EV(politique observée) – EV(équilibre)

- Un récitant y reste à zéro quel que soit l'adversaire ; un exploitateur s'en écarte positivement.
- **À adversaire fixé**, les deux mesures n'ont qu'un degré de liberté.

L'échelle de lecture

Adversaire	Joueur parfait	Récitant	Réf. récitée max
Over-folder	1,0000	0,2222	+0,7778
Station	0,3333	0,2222	+0,1111
GTO	0,0000	0,0000	0

La campagne exécutée

- 24 exécutions · 177 séries · 26 550 manches · 27 290 décisions de l'agent.
- gpt-5.6-luna, effort medium, K = 150, 3 réplifications, graine de campagne unique.
- **Coût** : 47,27 \$, sur deux jours et une machine unique.
- **Vérification** : 225 tests automatisés

4. Hypothèses

H1 : Il y a adaptation, et elle vient de la mémoire.

Face à un adversaire exploitable, l'écart d'exploitation d'un agent doté d'une mémoire persistante auto-rédigée décroît au fil des séries, tandis que celui du même modèle privé de mémoire reste stationnaire.

Mesure : pente de l'écart et écart final, condition AE contre condition SM.

Réfutation : AE ne se distingue pas de SM.

H3 : Le mécanisme de rétention détermine la forme.

La mémoire auto-rédigée produit une adaptation plus durable que la simple réinjection de l'historique brut, sujette à la saturation.

Mesure : trajectoire, écart final, aire sous la courbe, série d'atteinte du plateau.

Réfutation : ICL égale ou surpasse AE ; ou AE ne présente aucune accumulation.

H2 : L'adaptation est exploitative.

L'adaptation observée consiste à s'écarter de l'équilibre dans la direction que commande l'adversaire rencontré : cesser de bluffer, engager toutes les mains...

Mesure : signe et amplitude de la référence récitée, par adversaire.

Réfutation : l'écart ne descend que contre l'un des deux adversaires biaisés ; ou la référence récitée devient positive.

H4 : L'adaptation coexiste avec des biais persistants.

Même si sa politique s'améliore, l'agent conserve des défaillances et une incapacité à stabiliser.


Mesure : taux d'incohérence raisonnement ↔ action

Réfutation : les fréquences se stabilisent et l'incohérence devient négligeable.

5. Résultats - H1 : l'adaptation vient de la mémoire

Écart d'exploitation par série

Moyenne des 3 réplifications. Zéro = exploitation optimale.



Over-folder

0,704 → 0,000

réduction +0,704 · 3 réplifications sur 3

Station

0,222 → 0,002

réduction +0,220 · 2 réplifications à zéro exact

GTO


0,187 → 0,008

réduction +0,178

5. Résultats - H2 : elle exploite, elle ne récite pas

Fréquence d'engagement avec le sceau faible, selon l'adversaire

Même situation, trois réponses, dont deux opposées. Sans mémoire, rien ne les distingue.



Le contrôle négatif

- 39 séries contre l'adversaire à l'équilibre : la référence récitée n'est jamais positive, l'écart jamais négatif.
- Six séries atteignent exactement zéro.

L'asymétrie, le test décisif

- **Sans mémoire** : $0,285 \cdot 0,307 \cdot 0,355$ selon l'adversaire, pour un écart-type d'échantillonnage de 0,031. Rien ne les distingue, et c'est une propriété du dispositif.
- **Avec mémoire** : 1,000 contre Over-folder, 0,004 contre Station.
- **Aucune application de l'équilibre** ne produit ce contraste : l'équilibre est un objet fixe, calculé contre un adversaire supposé jouer lui-même l'équilibre.


L'amplitude, sur son maximum

Adversaire	SM	AE	Max	Atteint
Over-folder	+0,074	+0,778	+0,778	100 %
Station	-0,111	+0,110	+0,111	99 %
GTO	-0,187	-0,024	0	-

5. Résultats – H3 : le mécanisme de rétention

Après la première frontière — échelle resserrée

La mémoire écrite se verrouille sur zéro ; l'historique brut s'arrête au-dessus et n'y revient pas.



Les quatre décisions qui décident, contre Station

Décision	Meilleure rép.	ICL	AE
Engager le sceau faible : Ouvrant	0,000	0,065	0,006
Engager le sceau faible : Répondant	0,000	0,091	0,009
Engager le sceau fort : Ouvrant	1,000	0,973	1,000
Engager le sceau fort : Répondant	1,000	0,941	1,000


Ni la vitesse, ni l'oubli

- **ICL – AE** : +0,0381 contre Station (IC 95 % $\pm$ 0,0148, exclut zéro) ; +0,0039 contre Over-folder (contient zéro).
- **Aucun décrochage à la saturation.**
- **AE se verrouille sur zéro**
- **H3 est vérifiée, mais sous condition** : le mécanisme ne départage les deux mémoires que contre l'un des deux adversaires exploitables.

Une règle, ou deux

- **Over-folder** : une seule règle, positive. Les deux mécanismes l'extraient intégralement.
- **Station** : deux règles, dont une négative. Un engagement perdant figure dans l'historique comme une manche parmi 150 ; rien ne rassemble ces occurrences en interdiction.
- **L'apport est plus étroit que prévu** : la synthèse ne retient ni mieux ni plus longtemps, elle achève l'induction.

5. Résultats – H4 : ce que l'adaptation coûte



La dégénérescence

- Contre un adversaire à l'équilibre, bien jouer exige d'engager le sseau faible une fois sur trois, et de façon imprévisible.
- Sans mémoire : les fréquences se tiennent autour de 28%.
- Dès qu'une note existe il y a des fréquences extrêmes plus d'une série sur deux. Il n'a pas oublié comment jouer, il a cessé de tirer au sort.

Ce que les quatre-vingt-dix notes contiennent

Recherché dans les notes

	Occurrences
Un pourcentage (« 33 % »)	0
Une proportion en toutes lettres (« un tiers »)	0
Une fréquence prescrite pour sa propre action	0
Quantificateurs catégoriques (toujours, jamais)	221
Quantificateurs gradués (souvent, parfois)	228

Le même mécanisme

- Ce qui rend la mémoire auto-écrite supérieure est exactement ce qui la rend incapable de randomiser.
- Face à des bots figés, abandonner le mélange ne coûte rien. Un adversaire capable de s'ajuster est hors périmètre.
- Un agent doté de mémoire est un meilleur exploiteur et un adversaire plus prévisible.

6. Limites

Limites du travail

- Dispositif restreint : Repose sur seulement 3 répliques, 1 seul modèle, 1 tâche et un horizon de 10 séries.
- Le plateau étant atteint dès les premières frontières, la vitesse d'adaptation est mal résolue.
- La dégénérescence repose sur un seul ensemble d'information

Next Steps et Prolongements

- Des séries plus courtes et plus nombreuses pour mieux cerner la vitesse et l'oubli.
- Un jeu avec plusieurs ensembles d'information à équilibre mixte et plusieurs modèles.
- Affronter un adversaire biaisé puis à l'équilibre en conservant la mémoire (charge cognitive).
- Même protocole joué par des humains pour obtenir la référence comportementale manquante.
- Adversaire LLM : Intégrer un modèle de langage chez l'adversaire pour faire de la prévisibilité une variable dynamique.